Compte rendu du TP 3 MapReduce

Réalisation des exercices et captures des étapes

Nom et prénom : _____ Binôme : _____

Date : 13 octobre 2026

Le travail couvre les exercices présents dans l’énoncé réduit : comptage des mots, amis communs, tri global et horoscope, ainsi que leurs bonus. Le projet Maven, les données, les sorties HDFS et les journaux d’exécution sont joints. Chaque étape est documentée par une capture accompagnée d’une explication. Les vues HDFS et YARN sont capturées directement ; les autres captures montrent la consultation des journaux réels et des sorties enregistrées.

Organisation du compte rendu

Les réponses aux questions sont suivies des captures des étapes. Les figures documentent les outils, le projet, la compilation, le cluster, HDFS, YARN, le premier job, le chargement des données et chaque exécution des exercices.

Périmètre et statut des résultats

L'énoncé réduit contient les questions Q1-Q13 et Q20-Q28 : Q14-Q19 et l'exercice de jointure ne sont pas présents. Les quatre exercices présents sont résolus, ainsi que MotsParLivre, Suggestions et le bonus chinois. Les sources Java sont dans le projet Maven. Les données et sorties de référence sont jointes.

Les sorties et compteurs présentés ci-dessous proviennent d'exécutions réelles sur le cluster HDFS et YARN avec Hadoop 3.4.1. Le cluster possède deux DataNodes et deux NodeManagers, soit six conteneurs Docker. Les captures des interfaces HDFS/YARN, les journaux bruts et les sorties HDFS sont joints. Les calculs Python indépendants restent disponibles pour contrôler les résultats.

Partie 0

Q1. Les captures montrent deux DataNodes en service et deux NodeManagers RUNNING. Dernière ligne réelle du job : `Estimated value of Pi is 3.12000000000000000000`. Le journal indique une durée de 52,425 secondes. Le job comporte 2 tâches Map et 1 tâche Reduce, plus l'ApplicationMaster : au minimum 4 allocations de containers au cours du job, sans nouvelle tentative. Cela ne signifie pas 4 containers simultanés. Chaque mapper traite 100 échantillons. Le journal indique `uber mode : false` : les tâches utilisent leurs propres containers.

Q2. Un projet initial séparé avec les quatre classes vides des exercices a été compilé : le jar mesure **3 660 octets**. Le projet final, avec les bonus, produit un jar de **32 085 octets**, environ 31,3 Kio. La dépendance hadoop-client est `provided` : ses bibliothèques ne sont pas embarquées car elles sont déjà dans le cluster. Le jar contient le bytecode du projet et les métadonnées Maven. Le bytecode est ciblé Java 8 (major version 52).

Exercice 1 Mots

Q3. Sans filtre : (le,1), (soir,1), (le,1), (village,1), (entier,1), (attendait,1), (le,1), (retour,1), (des,1), (bateaux,1). Avec le/la/les/de/des : (soir,1), (village,1), (entier,1), (attendait,1), (retour,1), (bateaux,1). Pour village, le reducer reçoit [1,1,1] dans les mini-livres, ou des sommes partielles équivalentes après Combiner ; résultat 3.

Q4. Le premier job a réellement lancé **3 tâches Map**. Avec TextInputFormat, un FileSplit est créé par petit fichier ; les fichiers distincts ne sont pas fusionnés, malgré leur petite taille. CombineTextInputFormat permettrait de les regrouper.

Q5. Compteurs réels du second job : **GARDES=51**, **IGNORES=40**, Map output records=51, Combine input records=51, Combine output records=45, Reduce output records=42. Top 5, départagés par mot : [('mer', 4), ('données', 3), ('village', 3), ('ville', 2), ('voyage', 2)]. Le Combiner additionne localement les occurrences : 51 paires deviennent 45 avant le shuffle, puis le reducer produit 42 mots distincts. Le résultat est identique à une exécution sans Combiner. Ces compteurs ont été relevés dans le journal de l'exécution jointe ; d'autres volumes d'entrée peuvent conduire à plusieurs passages du Combiner.

Q6. Sortie HDFS réelle :

```
dans 3 {conte=1, science=3, voyage=1}
les 2 {conte=1, science=3}
mer 3 {conte=2, science=1, voyage=1}
ville 2 {science=1, voyage=1}
```

Le reducer ne peut pas être réutilisé comme Combiner : il reçoit des noms de livres mais produit un nombre et une représentation de dictionnaire. Les types sémantiques diffèrent et le seuil de livres ne doit pas être appliqué localement. Une combinaison adaptée utiliserait (mot,livre) et un compteur, puis une seconde agrégation.

Q7. Les cinq livres demandés ont été téléchargés, conservés avec leurs en-têtes et licences, chargés dans HDFS puis traités sur YARN : identifiants 1342, 84, 11, 2701 et 1661. Longueur minimale : 1. Liste des mots vides : celle de Q7.

Sans filtre. Top 5 réel : [('the', 31628), ('and', 17426), ('of', 16894), ('to', 14929), ('a', 11746)]. Combine input records=571470, Combine output records=42451, gain=92.57 %. Le job produit 22683 mots distincts.

Avec filtre. Top 5 réel : [('s', 3227), ('this', 3112), ('have', 3052), ('which', 2629), ('from', 2595)]. Combine input records=358906, Combine output records=42301, gain=88.21 %. Le job produit 22653 mots distincts.

Les fichiers joints fixent le corpus pour la reproduction ; les 18 livres anglais du pack ne sont pas confondus avec ces cinq livres.

Exercice 2 Amis

Q8. (Amina,Bilal ; Bilal,Chaima,Driss), (Amina,Chaima ; Bilal,Chaima,Driss), (Amina,Driss ; Bilal,Chaima,Driss). La paire canonique triée rassemble les émissions A→B et B→A sous la même clé.

Q9. Bilal,Chaima reçoit les listes Amina,Chaima,Driss,Elias et Amina,Bilal,Driss,Elias. Intersection : [Amina, Driss, Elias]. Les Text Hadoop sont réutilisés : leur contenu est copié dans des ensembles.

Q10. Sortie HDFS complète :

```
Amina,Bilal [Chaima, Driss]
Amina,Chaima [Bilal, Driss]
Amina,Driss [Bilal, Chaima]
Bilal,Chaima [Amina, Driss, Elias]
Bilal,Driss [Amina, Chaima, Elias]
Bilal,Elias [Chaima, Driss]
Chaima,Driss [Amina, Bilal, Elias]
Chaima,Elias [Bilal, Driss]
Driss,Elias [Bilal, Chaima]
```

Compteurs réels : Map output records=18 (3+4+4+4+3 liens dirigés), Reduce input groups=9 (9 arêtes non orientées), Reduce output records=9. Chaque groupe reçoit deux listes.

Q11. Le fichier asymétrique ajoute Farid:Amina,Bilal. Le job réel donne 20 sorties Map, 11 groupes Reduce et 9 lignes finales. **AMITIES_A_SENS_UNIQUE=2** : Amina,Farid et Bilal,Farid ne reçoivent qu'une liste. La sortie des neuf paires réciproques est conservée.

Q12. Pas de Combiner fondé sur le reducer proposé : il peut recevoir une seule liste et supprimer une paire valide avant le shuffle. Pour d=5000 amis, 5000 émissions transportent chacune une liste de 5000 noms, soit environ 25 millions de références à des noms : volume $O(d^2)$. L'intersection coûte $O(dA+dB)$ par paire avec des ensembles de hachage, avec un surcoût logarithmique pour les TreeSet ; le tri rend la sortie déterministe. Le bonus Suggestions génère $d(d-1)=24\ 995\ 000$ candidatures orientées.

Q13. Sortie HDFS réelle :

```
Amina Elias (3 en commun)
Bilal []
Chaima []
Driss []
Elias Amina (3 en commun)
```

Amina et Elias ne sont pas amis ; Bilal, Chaima et Driss sont leurs trois amis communs. Toutes les autres paires du graphe sont déjà directes.

Exercice 3 Tri (sections 4.x du PDF)

Q20. Le shuffle trie les clés Map dans chaque partition avant le Reduce. Map émet (nombre,NullWritable), car seule la clé est utile. Le reducer réécrit la clé une fois par valeur : sinon les doublons disparaîtraient. Aucun Combiner ne doit supprimer les occurrences.

Q21. Croissant : [0, 2, 3, 5, 7, 7, 7, 11, 19, 31, 42, 42, 64, 73, 88, 99, 150, 256, 512, 1000]. Décroissant : [1000, 512, 256, 150, 99, 88, 73, 64, 42, 42, 31, 19, 11, 7, 7, 7, 5, 3, 2, 0]. La ligne `job.setSortComparatorClass(LongWritable.DecreasingComparator.class)` inverse l'ordre. Avec plusieurs reducers, les indices des plages sont également inversés.

Q22. Résultats réellement relevés sur uniforme_1M.txt :

Reducer	Lignes	Première	Dernière
0	250118	0	249999
1	249244	250000	499999
2	250443	500000	749998
3	250195	750000	999999

Les plages sont [0,250000[, [250000,500000[, [500000,750000[, [750000,1000000[. Chaque partition est triée et les plages sont disjointes et ordonnées. La concaténation dans l'ordre des indices est donc triée globalement. La sortie réelle contient un million de lignes. Le contrôle indépendant compare la concaténation au tri de l'entrée et confirme la conservation de tous les doublons.

Q23. Effectifs réels par reducer sur le fichier biaisé : plages fixes **[706980, 134006, 89755, 69259]** ; échantillonnage Hadoop **[247195, 248025, 259921, 244859]**. RandomSampler échantillonne 10 % des lignes, jusqu'à 10 000 clés et 10 splits. InputSampler.writePartitionFile calcule des bornes adaptées à la distribution ; TotalOrderPartitioner affecte chaque clé à sa plage. L'échantillonnage vise des quantiles, ce qui répartit mieux la charge que des intervalles numériques égaux. Les sorties de ces deux jobs contiennent chacune un million de nombres, triés globalement avec tous les doublons conservés. Les bornes et effectifs peuvent changer lors d'une nouvelle exécution aléatoire. Les nombres sont écrits sur 7 chiffres pour que l'ordre lexicographique Text coïncide avec l'ordre numérique : 0000042 < 0000100. Sans remplissage, "100" < "42". Ce format suppose des entiers non négatifs de même largeur.

Exercice 4 Horoscope (sections 5.x)

Q24. 2004-03-25 : Bélier ; 2005-01-19 : Capricorne ; 2004-01-20 : Verseau ; 2003-12-21 : Sagittaire ; 2004-06-21 : Cancer ; 2005-06-20 : Gémeaux. Ces cas testent les frontières inclusives, particulièrement le passage janvier et juin. 2005-02-29 est impossible (année non bissextile) ; 2004-13-02 a un mois invalide. On incrémente DATES_INVALIDES et on ne les émet pas. LocalDate.parse vérifie réellement le calendrier ; le format AAAA-MM-JJ est imposé.

Q25. Map émet ("01 Bélier", "Amina Alaoui"), ou ("01 Bélier | Rabat", "Amina Alaoui") en mode ville. Le préfixe 01-12 donne l'ordre zodiacal par le tri des clés, au lieu de l'ordre alphabétique des signes. Avec plusieurs reducers, l'ordre global des signes nécessite un partitionnement adapté ou une fusion finale.

Q26. Sortie HDFS réelle :

```
01 Bélier 4 Amina Alaoui, Elias El Idrissi, Loubna Lahlou, Zakaria Zniber
05 Lion 4 Chaima Chraibi, Fatima Fassi, Jalil Jabri, Yasmine Yacoubi
08 Scorpion 3 Bilal Bennani, Kenza Kettani, Mehdi Mansouri
10 Capricorne 2 Driss Daoudi, Ghita Guessous
11 Verseau 2 Imane Idrissi, Taha Tazi
```

DATES_INVALIDES=2 ; 18 personnes valides. Les trois groupes unitaires, Gémeaux (Salma), Cancer (Omar) et Sagittaire (Nora), sont filtrés : 3 personnes omises et 15 affichées. Le job avec horoscope.min=1 produit huit groupes et affiche les 18 personnes valides.

Q27. Sortie HDFS réelle par signe et ville :

```
01 Bélier | Rabat 4 Amina Alaoui, Elias El Idrissi, Loubna Lahlou, Zakaria Zniber
05 Lion | Fès 2 Chaima Chraibi, Jalil Jabri
08 Scorpion | Casablanca 3 Bilal Bennani, Kenza Kettani, Mehdi Mansouri
11 Verseau | Tanger 2 Imane Idrissi, Taha Tazi
```

Le groupe Lion | Fès contient Chaima et Jalil. Fatima est à Agadir et Yasmine à Casablanca, chacune dans un groupe de taille 1 filtré. Le seuil s'applique à chaque couple signe-ville.

Q28. Il existe seulement 12 clés : au plus 12 reducers reçoivent des données, et les collisions de hachage peuvent réduire encore ce nombre. 20 reducers ne garantissent donc pas 12 actifs. Pour les 12 libellés exacts du TP, le HashPartitioner Hadoop (hash Text positif modulo 20) donne seulement 9 reducers distincts : 0, 2, 4, 5, 6, 7, 11, 12

et 15. Ce calcul a été vérifié avec les classes Hadoop 3.4.1. Les gros groupes imposent un fort coût mémoire si l'on stocke tous les noms. Pour des effectifs, additionner avec Combiner ; pour toutes les personnes, utiliser une clé (signe,identifiant) et diffuser plusieurs fragments par signe, ou une agrégation en deux étapes avec salage. Ajouter la ville augmente les clés seulement si le regroupement demandé l'autorise.

Bonus chinois. Option horoscope.chinois=true : animal=(année-4) modulo 12. Compteur CHINOIS_DATE_INCERTAINE pour janvier et les 20 premiers jours de février. Le résultat reste une approximation signalée, car les dates du Nouvel An chinois ne sont pas fournies.

Exécution et validation finale

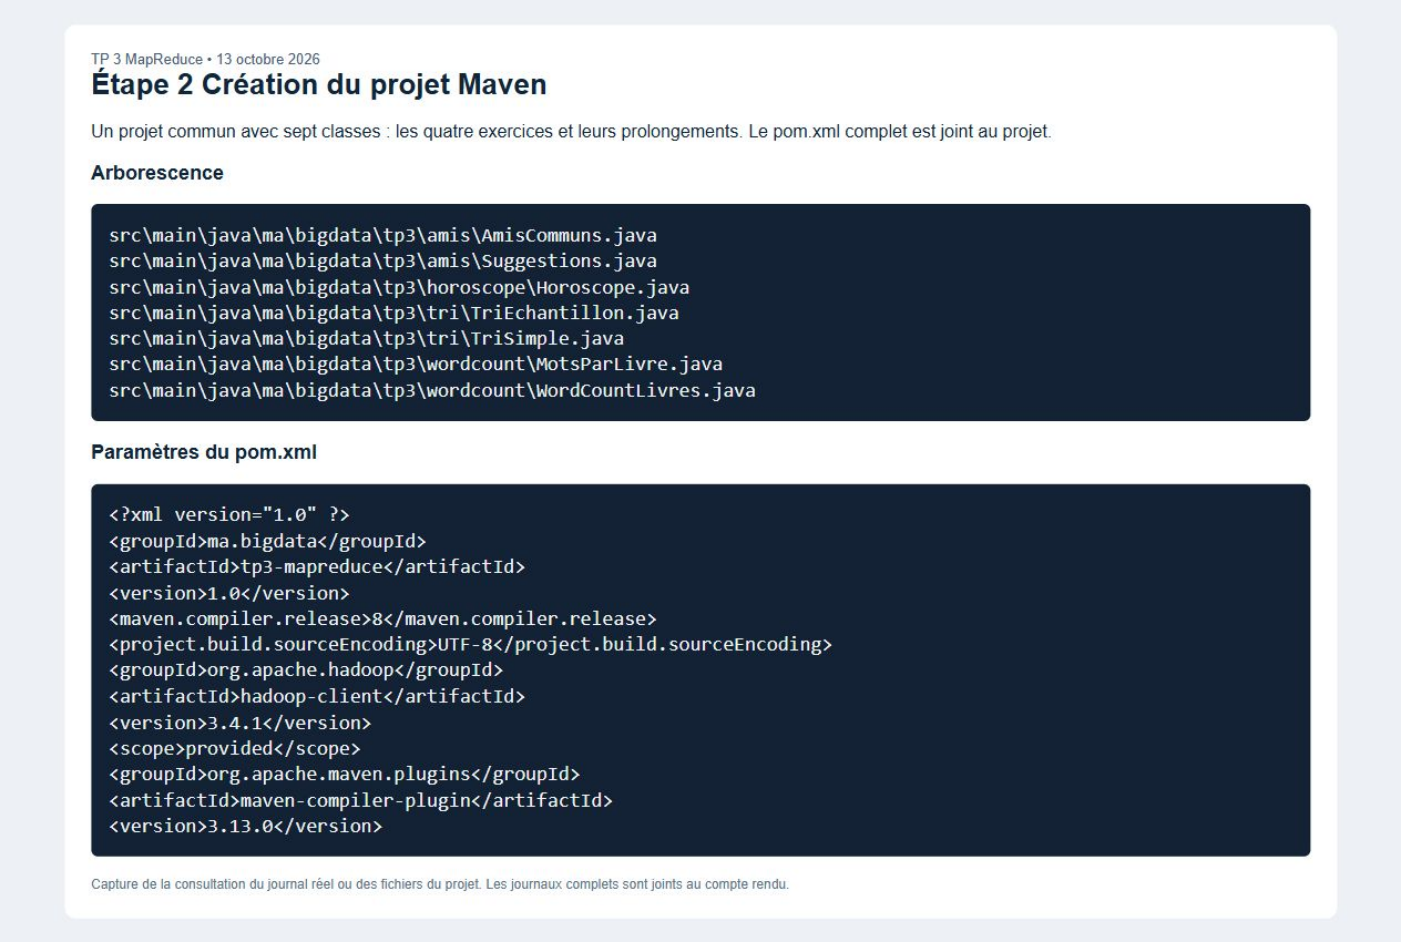
Tous les jobs exécutés sont terminés avec succès. Les captures documentent les étapes et les journaux complets sont conservés dans traces/. Le grand horoscope contient 486 dates invalides et 99 514 personnes valides. Le bonus chinois signale 3 dates incertaines sur les mini-données. Les données de jointure restent disponibles mais les questions correspondantes sont absentes de l’énoncé réduit.

Figure 1 Vérification des versions Docker Compose et Java.



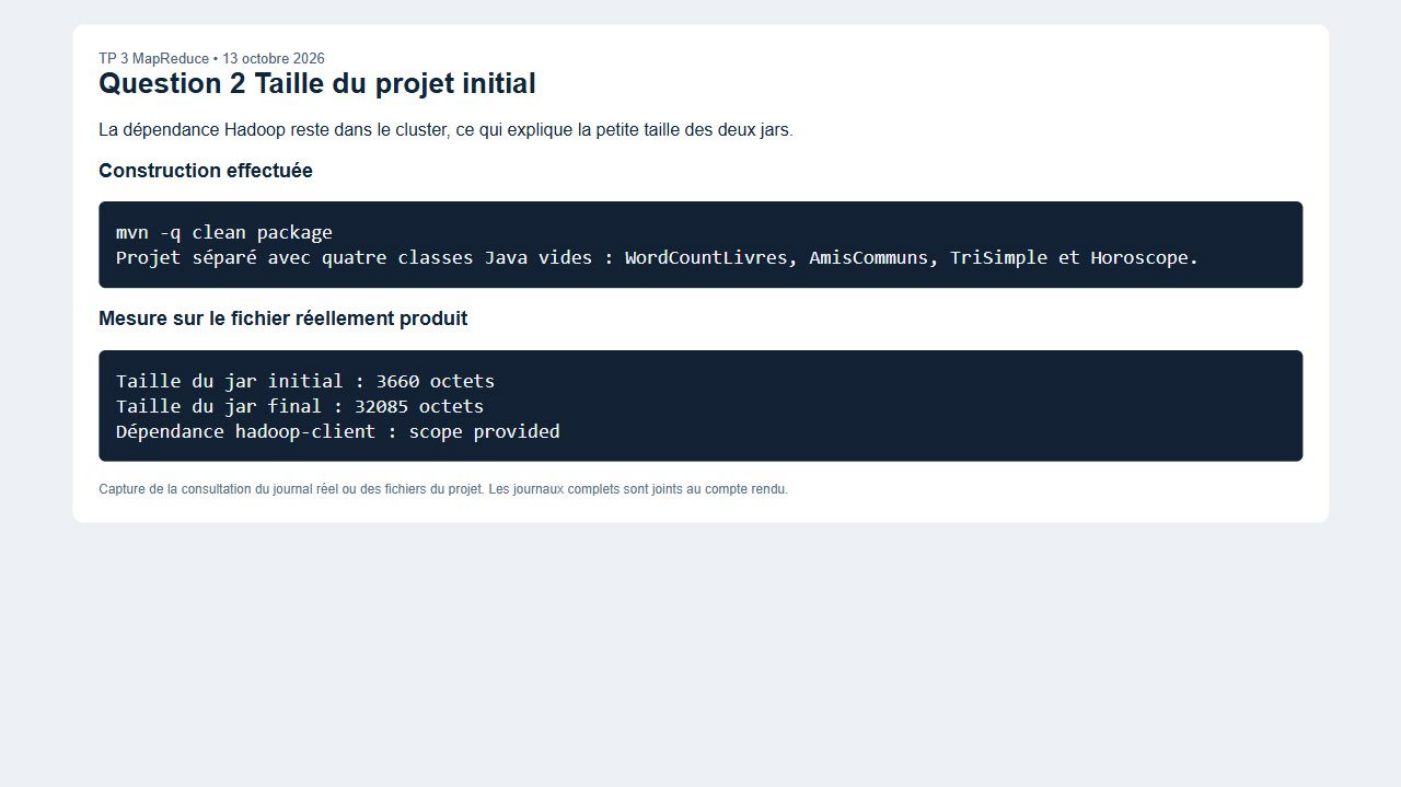
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 2 Création du projet Maven et organisation des sept classes Java.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 3 Mesure du jar initial contenant quatre classes vides pour Q2.



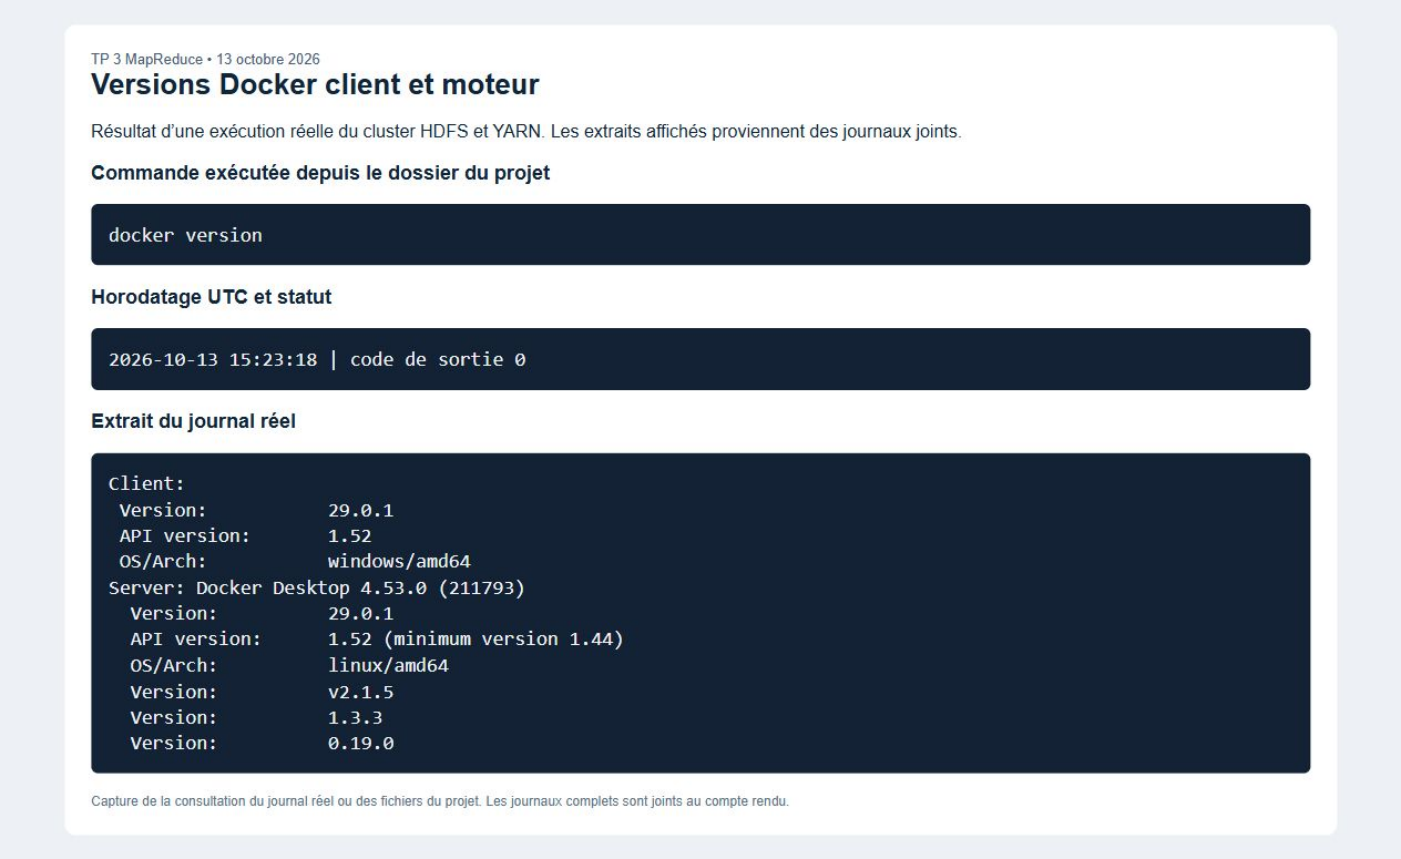
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 4 Compilation réussie des sept classes et production du jar.



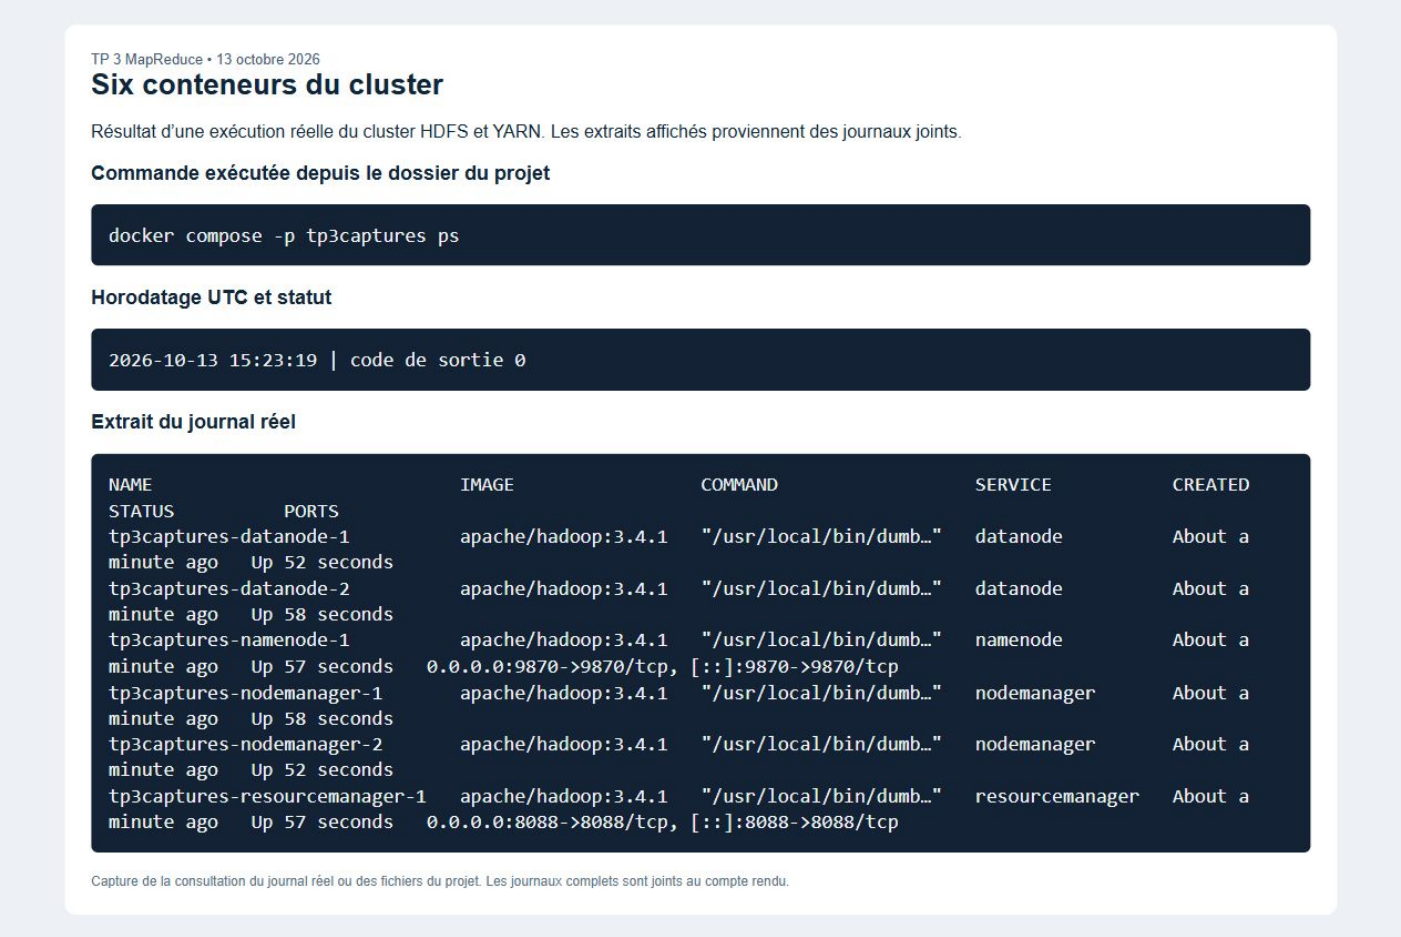
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 5 Vérification du client et du moteur Docker après démarrage.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 6 Les six conteneurs du cluster sont en fonctionnement.



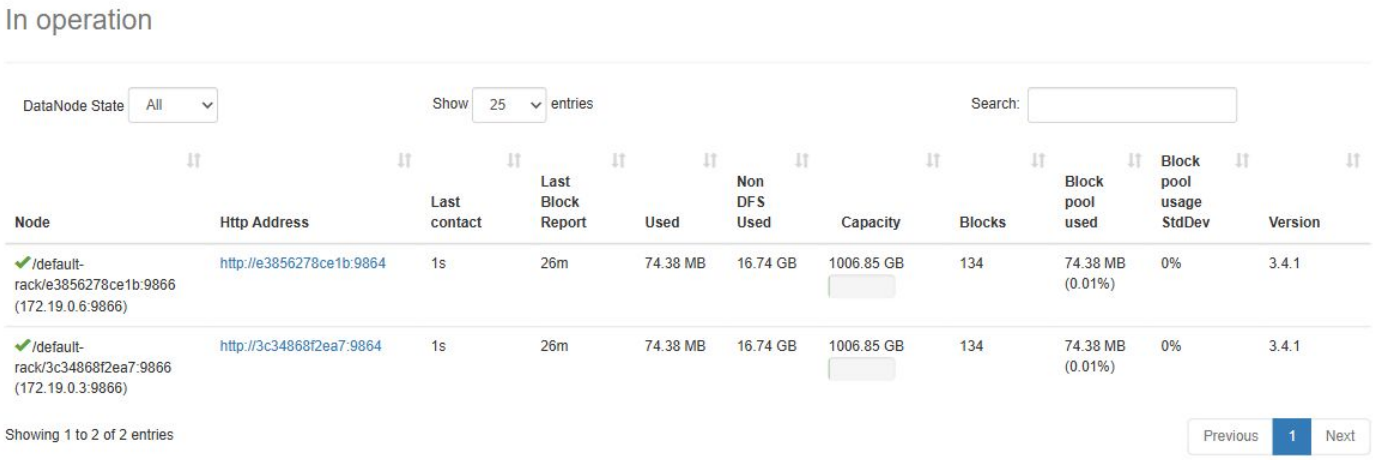
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 7 Le rapport HDFS permet de vérifier les deux DataNodes.



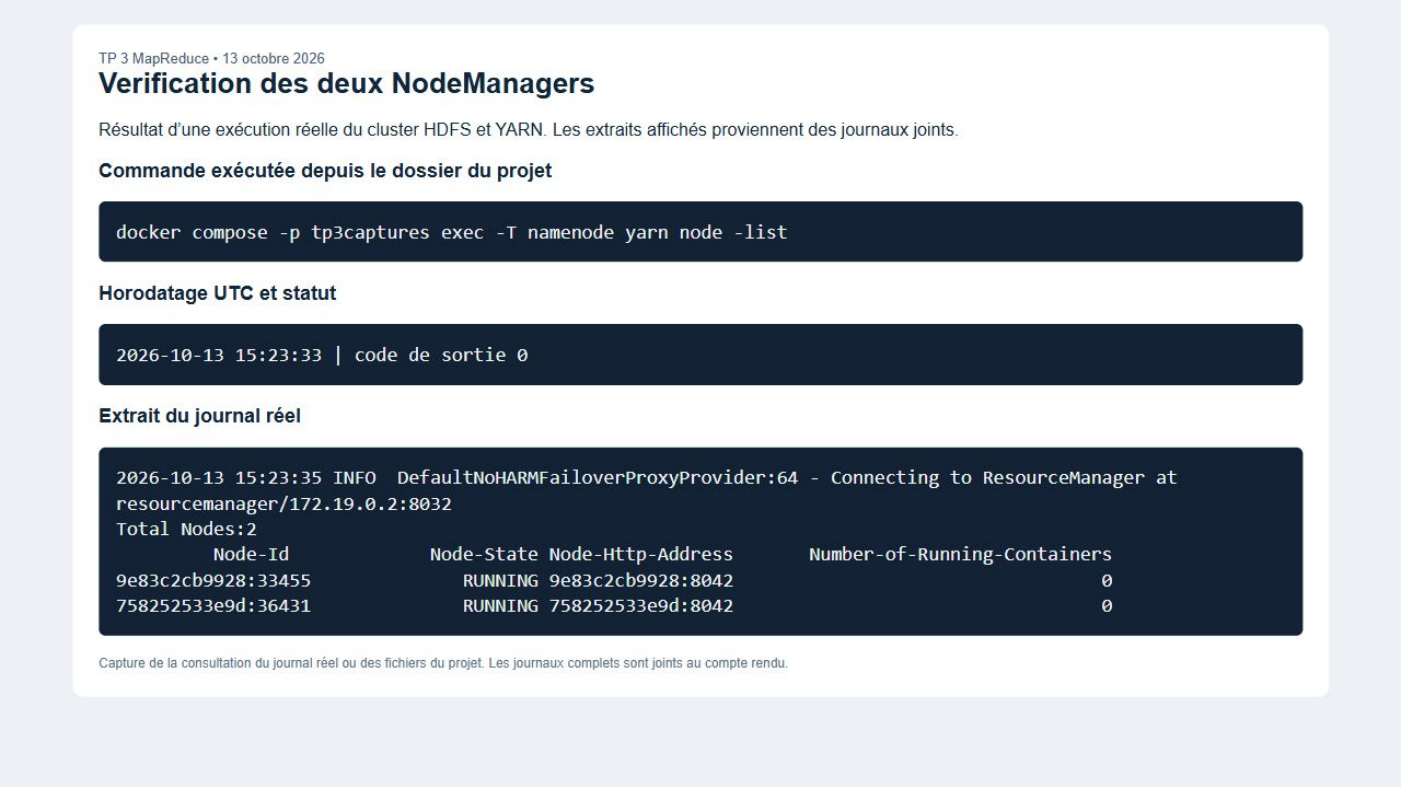
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 8 Interface HDFS à localhost:9870 et ses deux DataNodes.



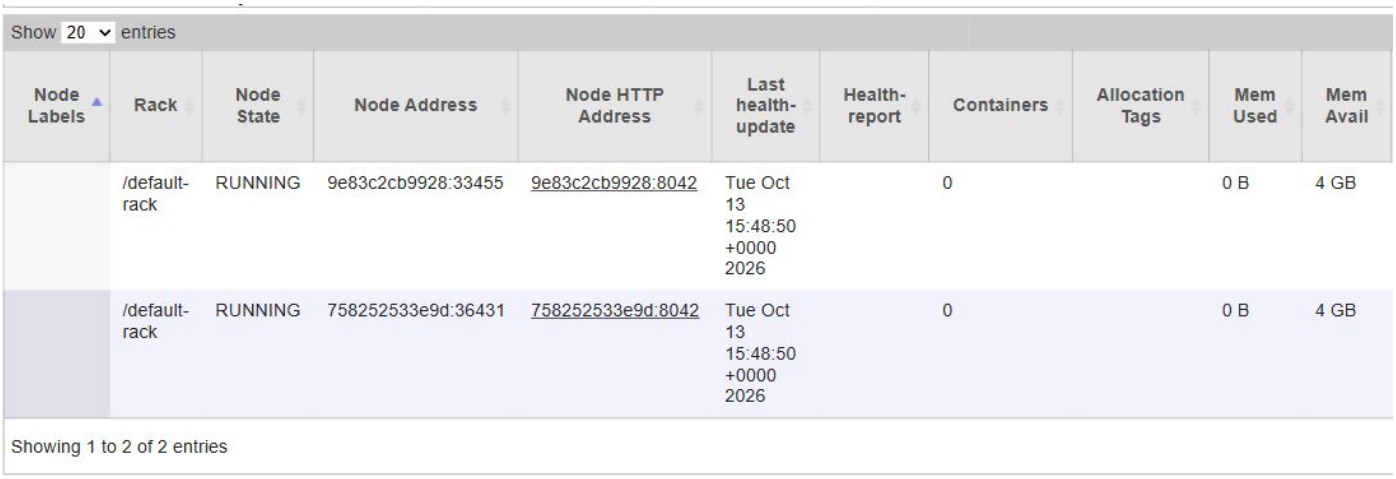
Source : capture de l’interface web du cluster.

Figure 9 La liste YARN permet de vérifier les deux NodeManagers actifs.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 10 Interface YARN à localhost:8088 et ses deux NodeManagers.



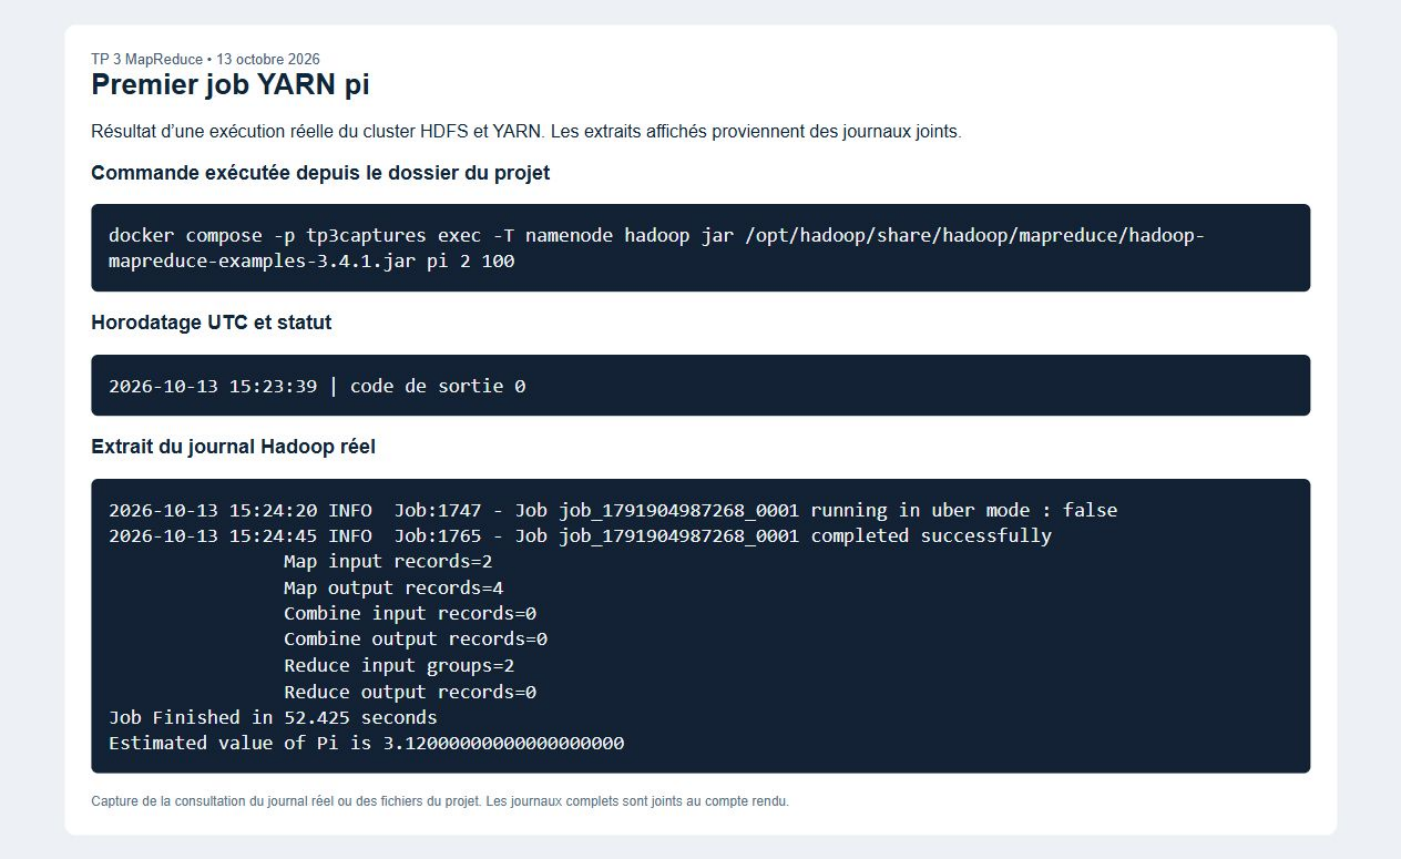
Show 20 entries

Node Labels	Rack	Node State	Node Address	Node HTTP Address	Last health-update	Health-report	Containers	Allocation Tags	Mem Used	Mem Avail
	/default-rack	RUNNING	9e83c2cb9928:33455	9e83c2cb9928:8042	Tue Oct 13 15:48:50 +0000 2026		0		0 B	4 GB
	/default-rack	RUNNING	758252533e9d:36431	758252533e9d:8042	Tue Oct 13 15:48:50 +0000 2026		0		0 B	4 GB

Showing 1 to 2 of 2 entries

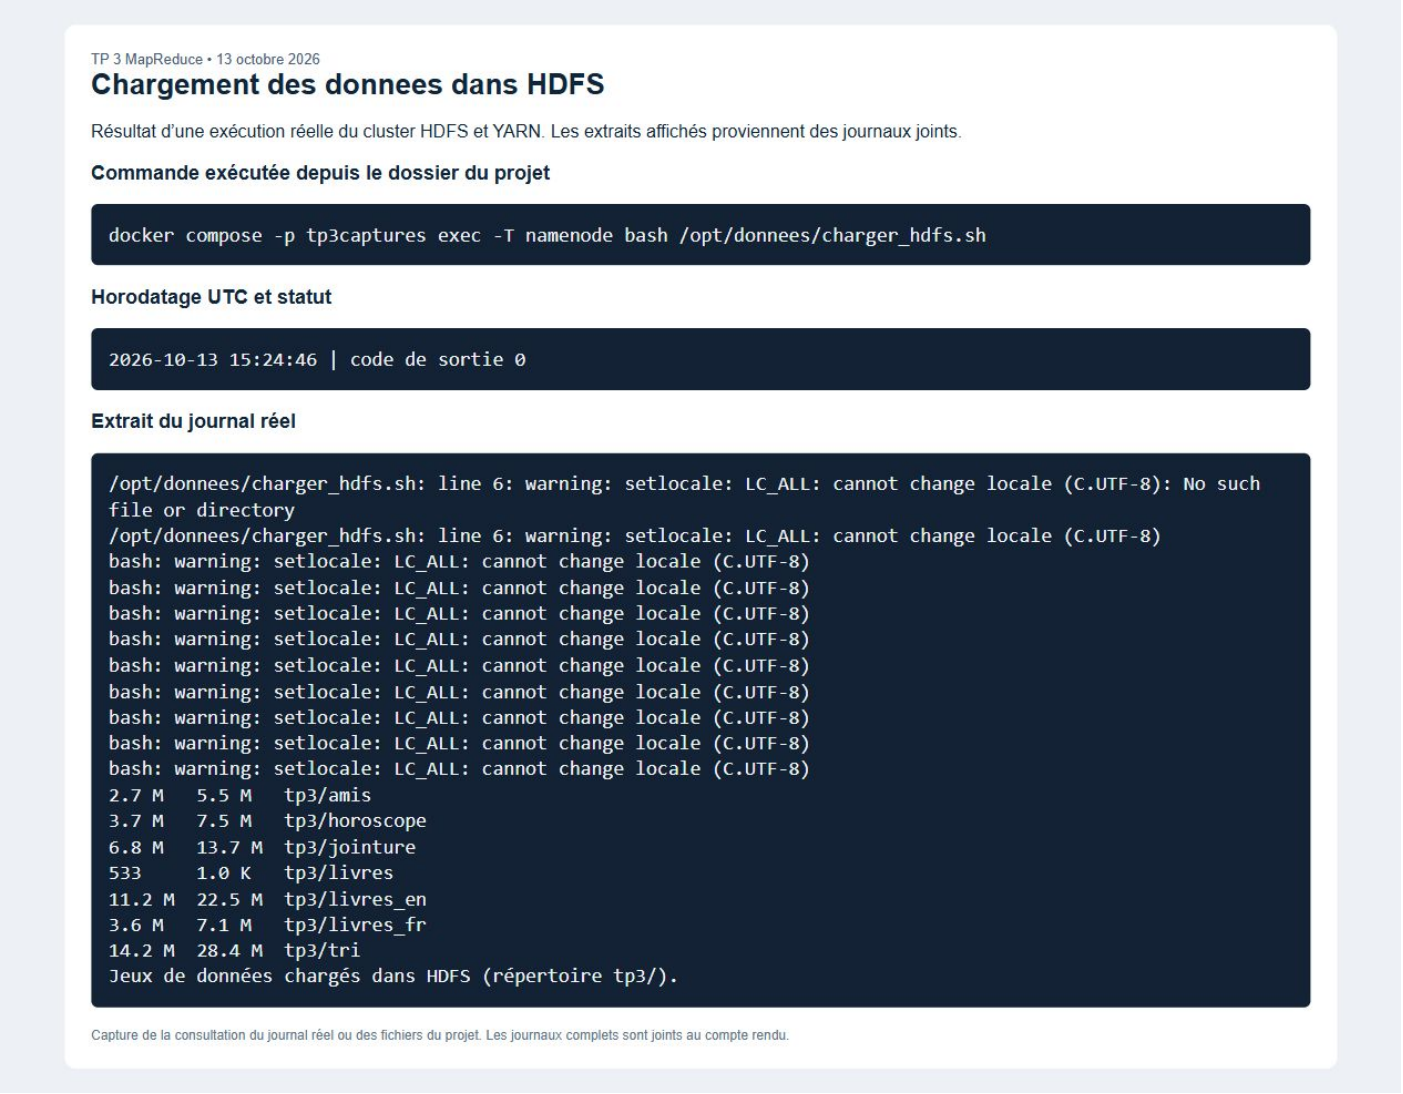
Source : capture de l’interface web du cluster.

Figure 11 Premier job MapReduce exécuté sur YARN et estimation de pi.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 12 Chargement de tous les jeux de données du pack dans HDFS.



TP 3 MapReduce • 13 octobre 2026

Chargement des donnees dans HDFS

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode bash /opt/donnees/charger_hdfs.sh
```

Horodatage UTC et statut

```
2026-10-13 15:24:46 | code de sortie 0
```

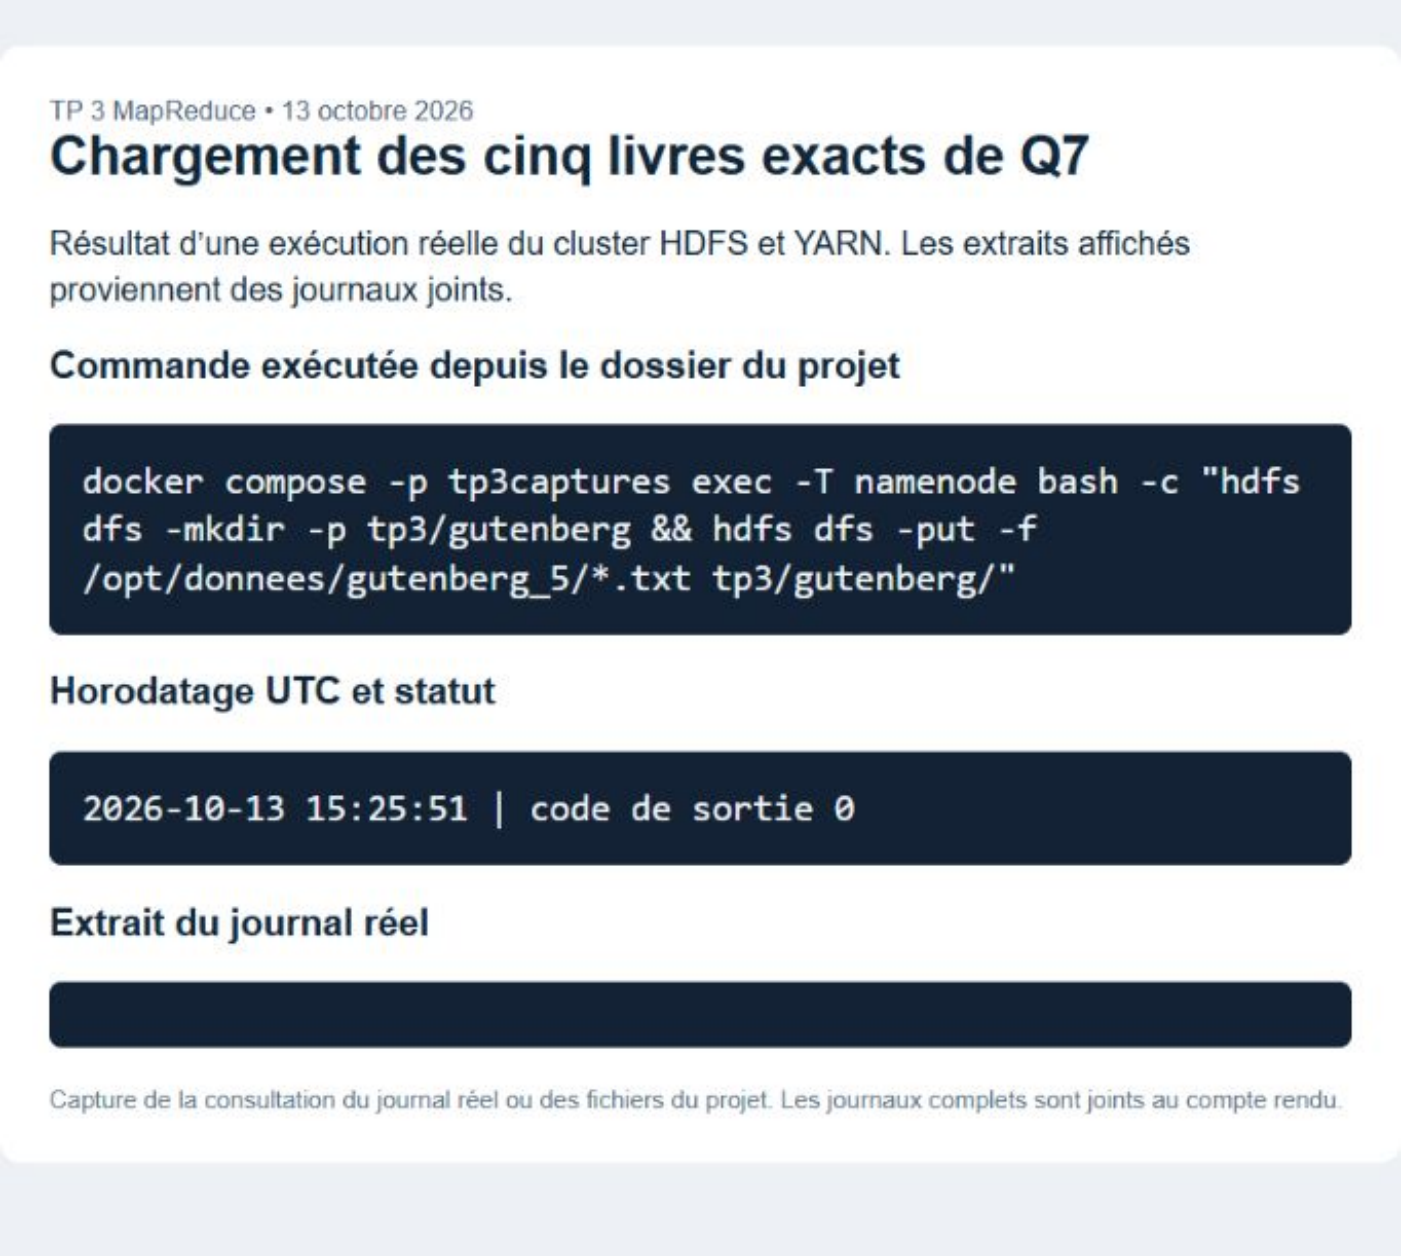
Extrait du journal réel

```
/opt/donnees/charger_hdfs.sh: line 6: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8): No such
file or directory
/opt/donnees/charger_hdfs.sh: line 6: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
bash: warning: setlocale: LC_ALL: cannot change locale (C.UTF-8)
2.7 M   5.5 M   tp3/amis
3.7 M   7.5 M   tp3/horoscope
6.8 M   13.7 M  tp3/jointure
533     1.0 K   tp3/livres
11.2 M  22.5 M  tp3/livres_en
3.6 M   7.1 M   tp3/livres_fr
14.2 M  28.4 M  tp3/tri
Jeux de données chargés dans HDFS (répertoire tp3/).
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 13 Chargement des cinq livres exacts demandés par Q7.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 14 Comptage des mini-livres sans filtre et compteurs Map et Reduce.



TP 3 MapReduce • 13 octobre 2026

07_wc1

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar
/opt/jobs/tp3.jar ma.bigdata.tp3.wordcount.WordCountLivres
tp3/livres tp3/out/captures_1791905161/07_wc1
```

Horodatage UTC et statut

```
2026-10-13 15:26:01 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:26:38 INFO  Job:1747 - Job
job_1791904987268_0002 running in uber mode : false
2026-10-13 15:27:26 INFO  Job:1765 - Job
job_1791904987268_0002 completed successfully
                Map input records=9
                Map output records=91
                Combine input records=91
                Combine output records=72
                Reduce input groups=60
                Reduce output records=60
                GARDES=91
```

Top 10 calculé à partir de la sortie HDFS

```
la      7
le      7
dans    5
les     4
mer     4
données 3
en      3
village 3
un      2
ville   2
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 15 Comptage avec filtre et top des mots conservés.

TP 3 MapReduce • 13 octobre 2026

08_wc2

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar
/opt/jobs/tp3.jar ma.bigdata.tp3.wordcount.WordCountLivres
-D
wc.mots.vides=le,la,les,de,des,dans,en,un,une,et,au,ce,l,il
,son,par,puis -D wc.longueur.min=2 tp3/livres
tp3/out/captures_1791905161/08_wc2
```

Horodatage UTC et statut

```
2026-10-13 15:26:01 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:26:37 INFO  Job:1747 - Job
job_1791904987268_0003 running in uber mode : false
2026-10-13 15:27:26 INFO  Job:1765 - Job
job_1791904987268_0003 completed successfully
                Map input records=9
                Map output records=51
                Combine input records=51
                Combine output records=45
                Reduce input groups=42
                Reduce output records=42
                GARDES=51
                IGNORES=40
```

Top 10 calculé à partir de la sortie HDFS

```
mer     4
données 3
village 3
ville   2
voyage  2
apparaît        1
attendait       1
aube    1
bateaux 1
beau    1
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 16 Nombre de livres contenant chaque mot et détail des occurrences.

TP 3 MapReduce • 13 octobre 2026

09_mpl

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar
/opt/jobs/tp3.jar ma.bigdata.tp3.wordcount.MotsParLivre -D
mpl.livres.min=2 tp3/livres
tp3/out/captures_1791905161/09_mpl
```

Horodatage UTC et statut

```
2026-10-13 15:27:34 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:28:04 INFO  Job:1747 - Job
job_1791904987268_0005 running in uber mode : false
2026-10-13 15:29:06 INFO  Job:1765 - Job
job_1791904987268_0005 completed successfully
               Map input records=9
               Map output records=65
               Combine input records=0
               Combine output records=0
               Reduce input groups=49
               Reduce output records=4
```

Sortie HDFS

```
dans    3       {conte=1, science=3, voyage=1}
les     2       {conte=1, science=3}
mer     3       {conte=2, science=1, voyage=1}
ville   2       {science=1, voyage=1}
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 17 Comptage des cinq livres Gutenberg sans filtre.

TP 3 MapReduce • 13 octobre 2026

10_gutenberg

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar
/opt/jobs/tp3.jar ma.bigdata.tp3.wordcount.WordCountLivres
tp3/gutenberg tp3/out/captures_1791905161/10_gutenberg
```

Horodatage UTC et statut

```
2026-10-13 15:27:34 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:28:04 INFO  Job:1747 - Job
job_1791904987268_0004 running in uber mode : false
2026-10-13 15:29:08 INFO  Job:1765 - Job
job_1791904987268_0004 completed successfully
                Map input records=61059
                Map output records=571470
                Combine input records=571470
                Combine output records=42451
                Reduce input groups=22683
                Reduce output records=22683
                GARDES=571470
                IGNORES=17962
```

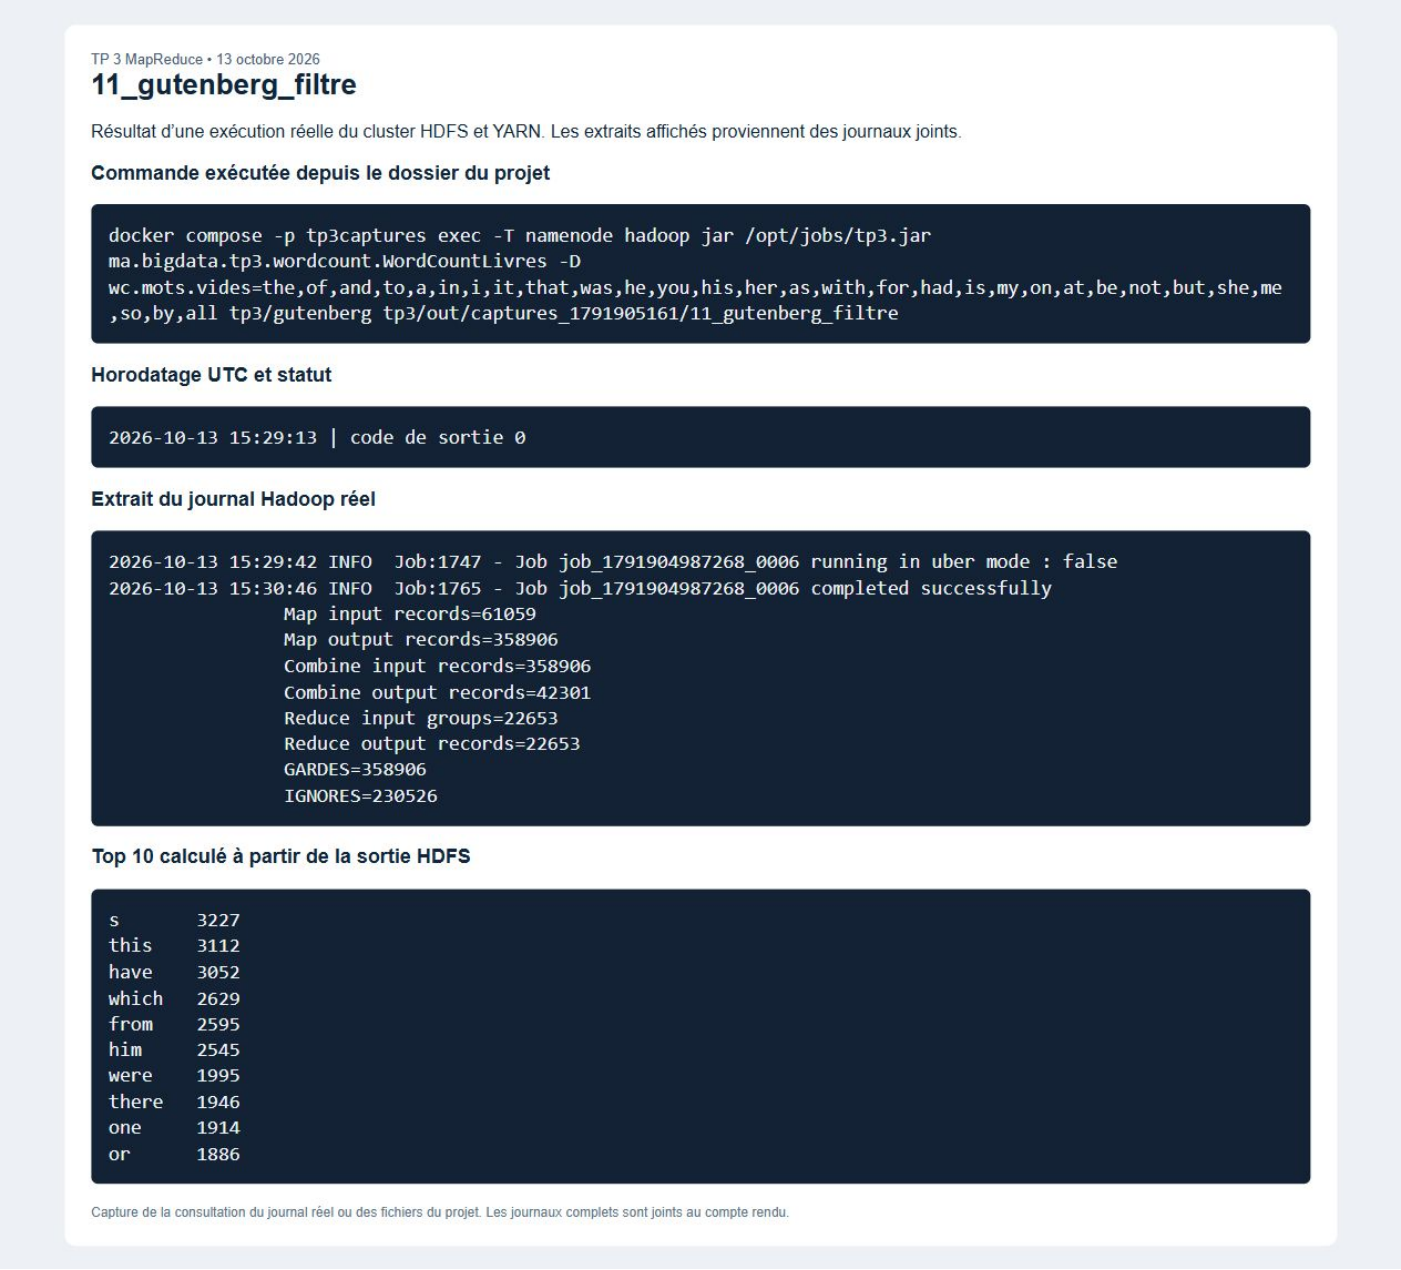
Top 10 calculé à partir de la sortie HDFS

```
the     31628
and     17426
of      16894
to      14929
a       11746
i       10683
in      9747
that    7891
it      7063
was     6319
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 18 Comptage Gutenberg avec les mots vides de Q7.



TP 3 MapReduce • 13 octobre 2026

11_gutenberg_filtre

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar
ma.bigdata.tp3.wordcount.WordCountLivres -D
wc.mots.vides=the,of,and,to,a,in,i,it,that,was,he,you,his,her,as,with,for,had,is,my,on,at,be,not,but,she,me
,so,by,all tp3/gutenberg tp3/out/captures_1791905161/11_gutenberg_filtre
```

Horodatage UTC et statut

```
2026-10-13 15:29:13 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:29:42 INFO  Job:1747 - Job job_1791904987268_0006 running in uber mode : false
2026-10-13 15:30:46 INFO  Job:1765 - Job job_1791904987268_0006 completed successfully
               Map input records=61059
               Map output records=358906
               Combine input records=358906
               Combine output records=42301
               Reduce input groups=22653
               Reduce output records=22653
               GARDES=358906
               IGNORES=230526
```

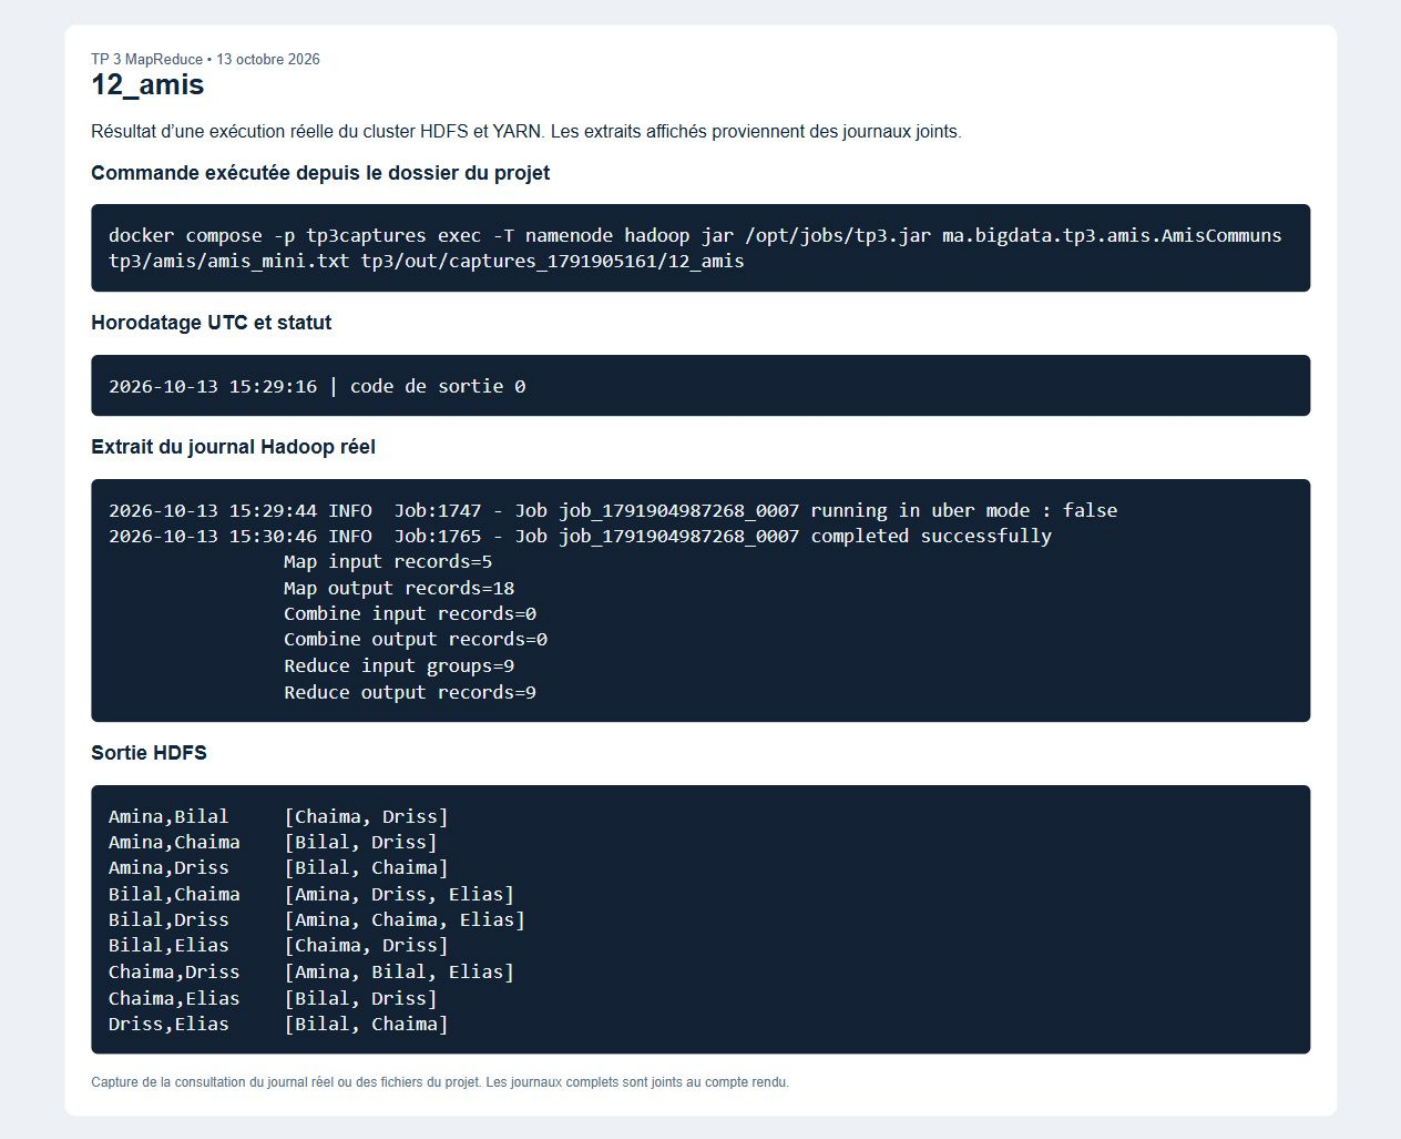
Top 10 calculé à partir de la sortie HDFS

```
s       3227
this    3112
have    3052
which   2629
from    2595
him     2545
were    1995
there   1946
one     1914
or      1886
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 19 Intersections des listes des neuf paires d’amis.



TP 3 MapReduce • 13 octobre 2026

12_amis

Résultat d’une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar ma.bigdata.tp3.amis.AmisCommuns
tp3/amis/amis_mini.txt tp3/out/captures_1791905161/12_amis
```

Horodatage UTC et statut

```
2026-10-13 15:29:16 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:29:44 INFO  Job:1747 - Job job_1791904987268_0007 running in uber mode : false
2026-10-13 15:30:46 INFO  Job:1765 - Job job_1791904987268_0007 completed successfully
               Map input records=5
               Map output records=18
               Combine input records=0
               Combine output records=0
               Reduce input groups=9
               Reduce output records=9
```

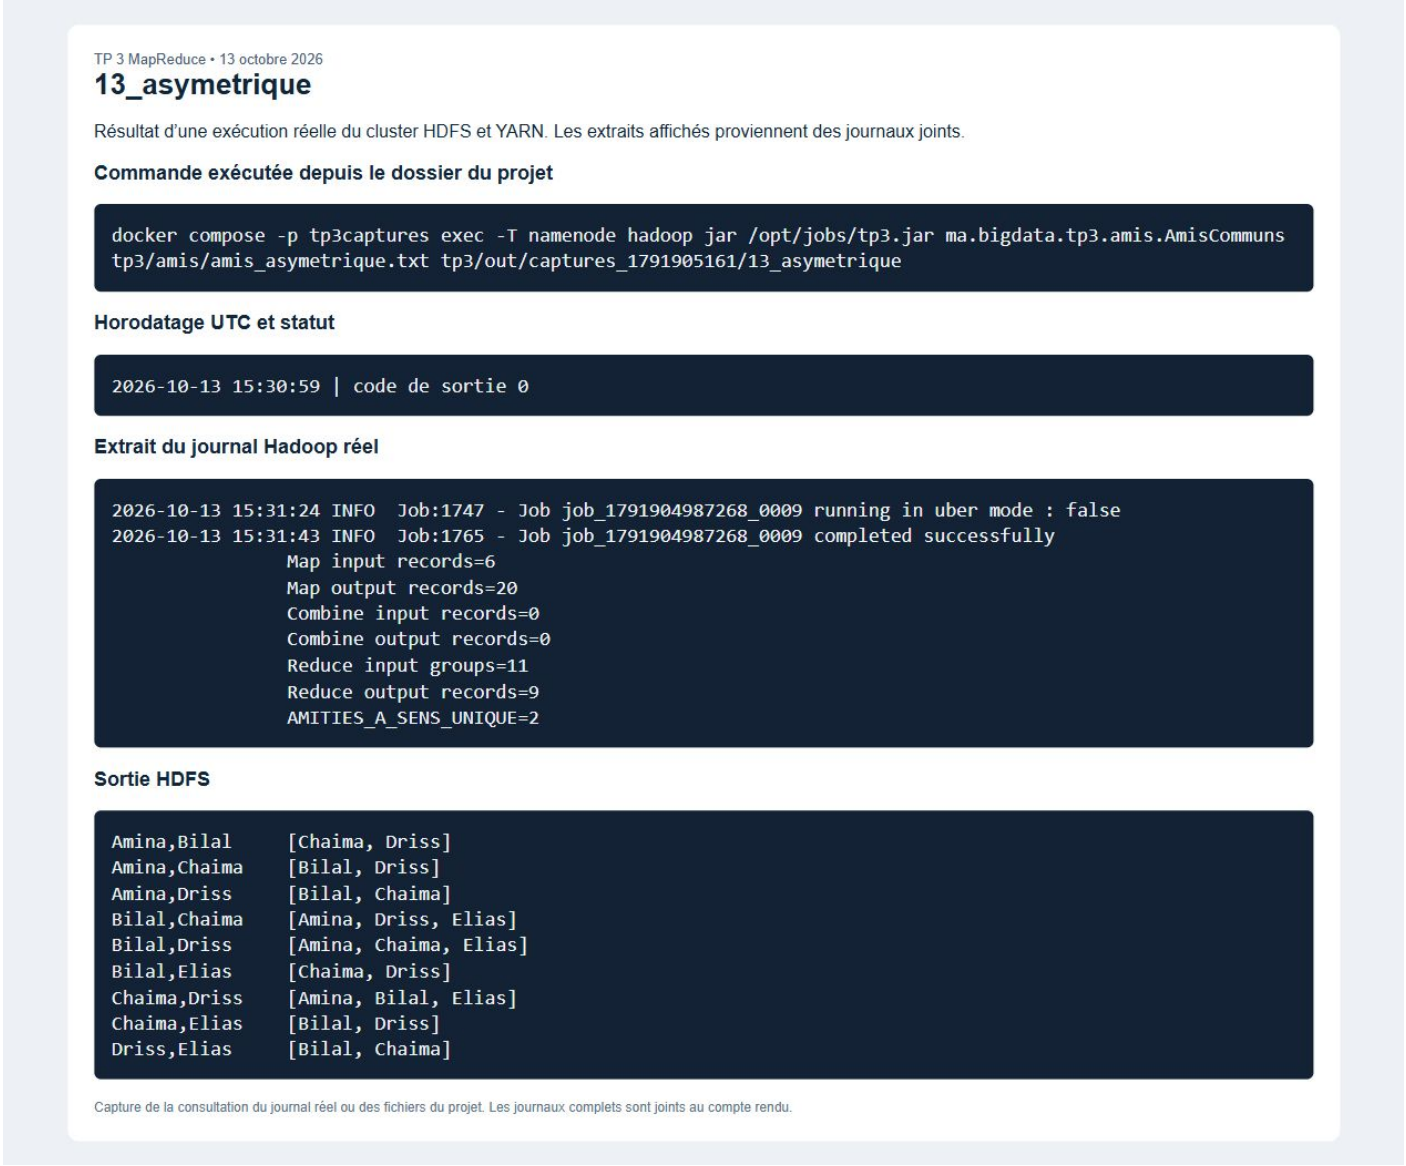
Sortie HDFS

```
Amina,Bilal     [Chaima, Driss]
Amina,Chaima    [Bilal, Driss]
Amina,Driss     [Bilal, Chaima]
Bilal,Chaima    [Amina, Driss, Elias]
Bilal,Driss     [Amina, Chaima, Elias]
Bilal,Elias     [Chaima, Driss]
Chaima,Driss    [Amina, Bilal, Elias]
Chaima,Elias    [Bilal, Driss]
Driss,Elias     [Bilal, Chaima]
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 20 Les liens à sens unique de Farid sont détectés par un compteur.



TP 3 MapReduce • 13 octobre 2026

13_asymetrique

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar ma.bigdata.tp3.amis.AmisCommuns
tp3/amis/amis_asymetrique.txt tp3/out/captures_1791905161/13_asymetrique
```

Horodatage UTC et statut

```
2026-10-13 15:30:59 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:31:24 INFO  Job:1747 - Job job_1791904987268_0009 running in uber mode : false
2026-10-13 15:31:43 INFO  Job:1765 - Job job_1791904987268_0009 completed successfully
               Map input records=6
               Map output records=20
               Combine input records=0
               Combine output records=0
               Reduce input groups=11
               Reduce output records=9
               AMITIES_A_SENS_UNIQUE=2
```

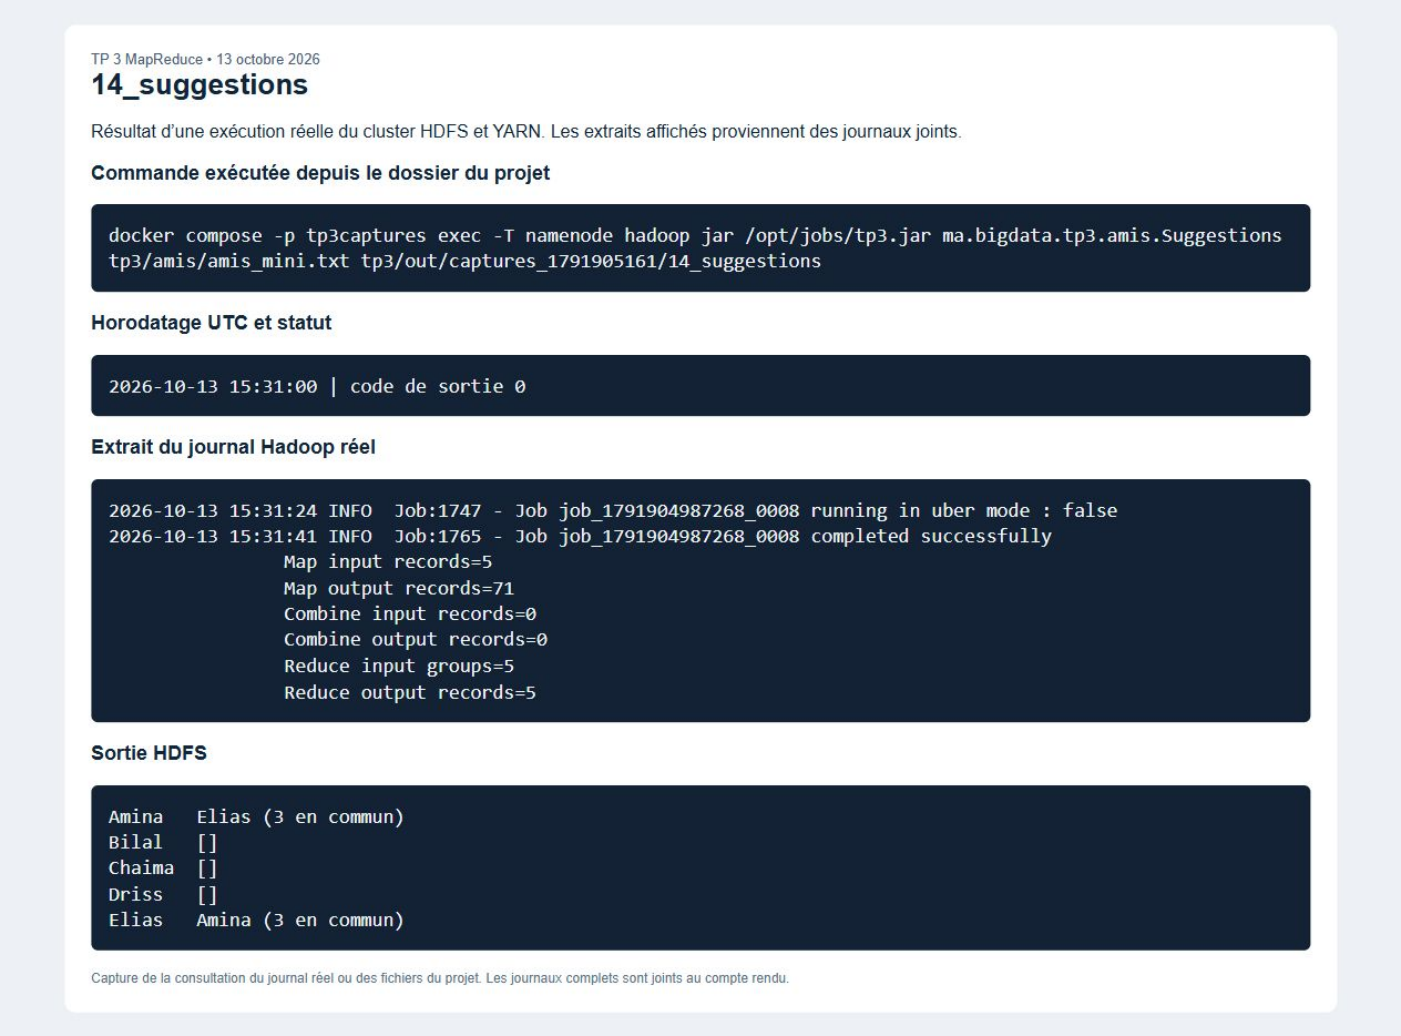
Sortie HDFS

```
Amina,Bilal     [Chaima, Driss]
Amina,Chaima    [Bilal, Driss]
Amina,Driss     [Bilal, Chaima]
Bilal,Chaima    [Amina, Driss, Elias]
Bilal,Driss     [Amina, Chaima, Elias]
Bilal,Elias     [Chaima, Driss]
Chaima,Driss    [Amina, Bilal, Elias]
Chaima,Elias    [Bilal, Driss]
Driss,Elias     [Bilal, Chaima]
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 21 Suggestions d’amis et classement par amis en commun.



TP 3 MapReduce • 13 octobre 2026

14_suggestions

Résultat d’une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar ma.bigdata.tp3.amis.Suggestions
tp3/amis/amis_mini.txt tp3/out/captures_1791905161/14_suggestions
```

Horodatage UTC et statut

```
2026-10-13 15:31:00 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:31:24 INFO  Job:1747 - Job job_1791904987268_0008 running in uber mode : false
2026-10-13 15:31:41 INFO  Job:1765 - Job job_1791904987268_0008 completed successfully
               Map input records=5
               Map output records=71
               Combine input records=0
               Combine output records=0
               Reduce input groups=5
               Reduce output records=5
```

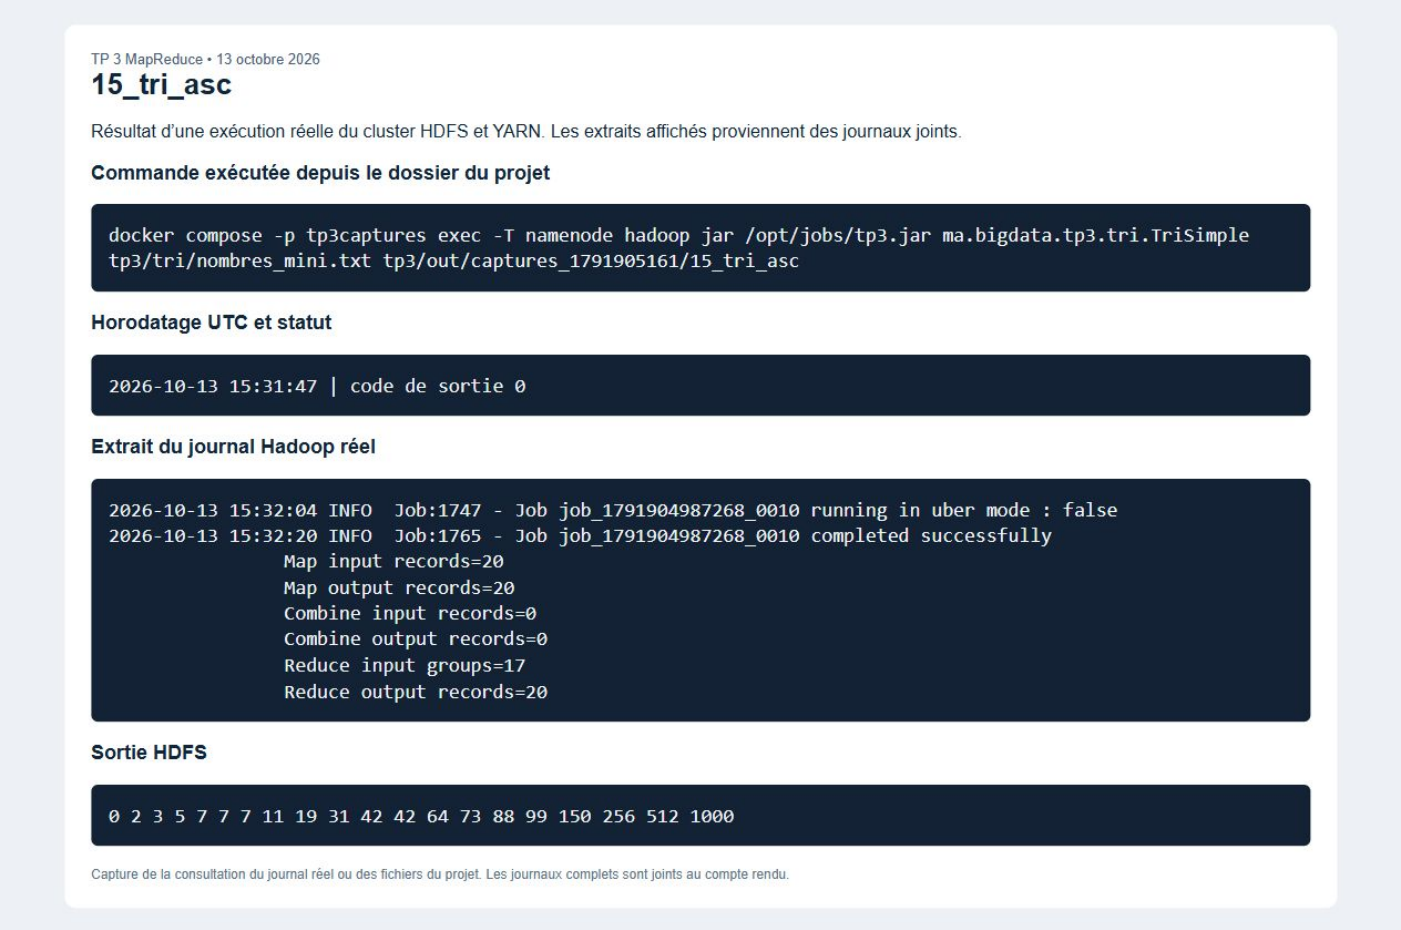
Sortie HDFS

```
Amina   Elias (3 en commun)
Bilal   []
Chaima  []
Driss   []
Elias   Amina (3 en commun)
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

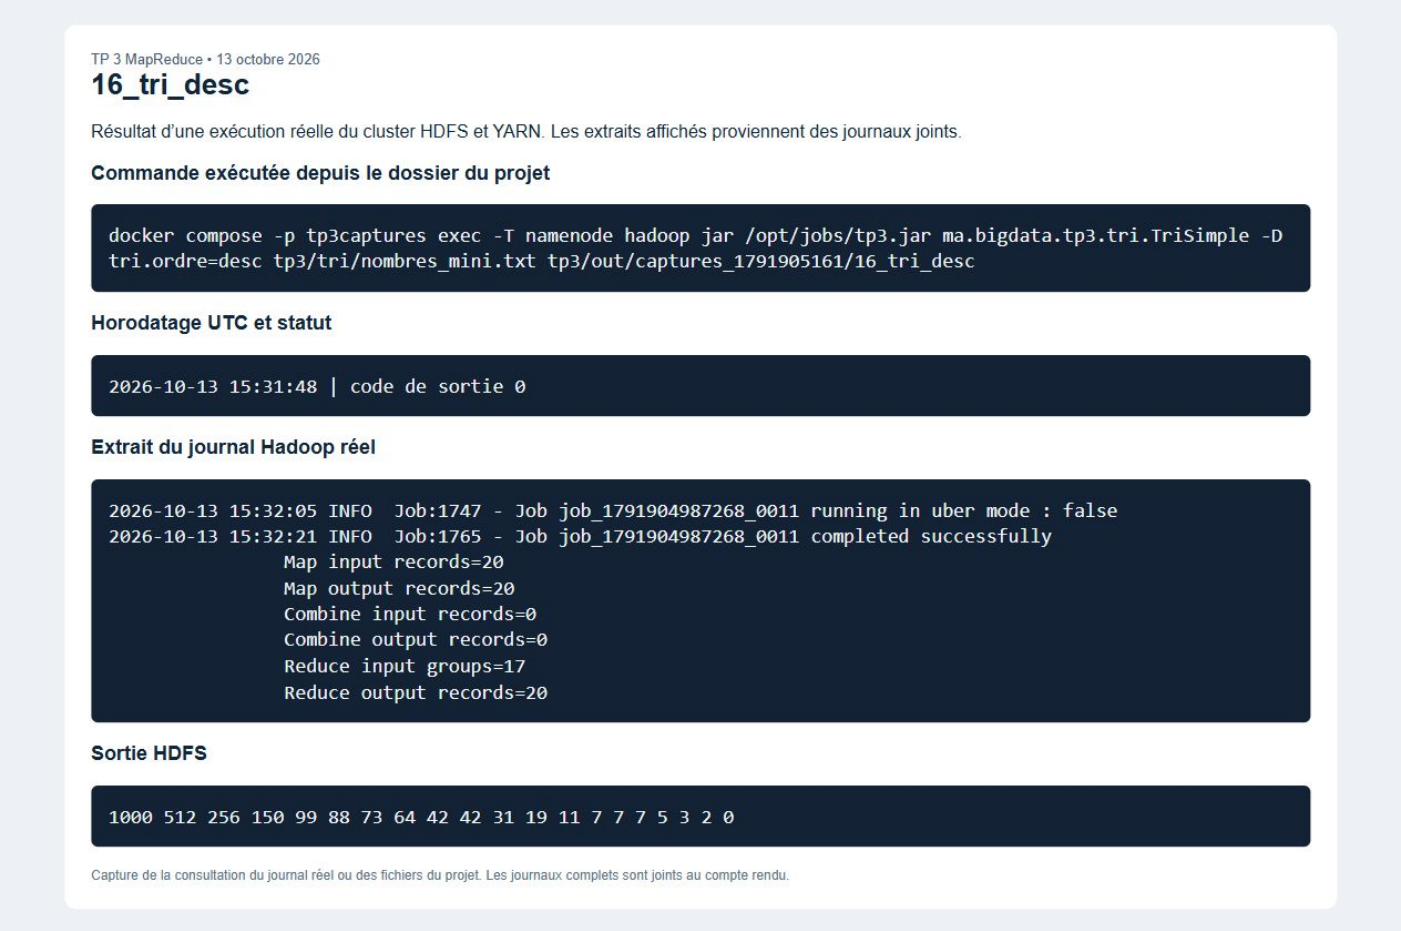
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 22 Tri croissant du petit tableau avec conservation des doublons.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 23 Tri décroissant du petit tableau.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 24 Tri du million de nombres uniformes sur quatre reducers.



TP 3 MapReduce • 13 octobre 2026

17_tri_grand

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar ma.bigdata.tp3.tri.TriSimple -D
tri.reducers=4 tp3/tri/uniforme_1M.txt tp3/out/captures_1791905161/17_tri_grand
```

Horodatage UTC et statut

```
2026-10-13 15:32:24 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:32:41 INFO  Job:1747 - Job job_1791904987268_0012 running in uber mode : false
2026-10-13 15:33:15 INFO  Job:1765 - Job job_1791904987268_0012 completed successfully
               Map input records=1000000
               Map output records=1000000
               Combine input records=0
               Combine output records=0
               Reduce input groups=631532
               Reduce output records=1000000
```

Extrait de la sortie HDFS

```
Premières valeurs : 0 2 2 3 3
1000000 lignes au total
Dernières valeurs : 999994 999996 999997 999998 999999
```

Effectifs et bornes par reducer

```
part-r-00000
lignes=250118 premiere=0 derniere=249999
part-r-00001
lignes=249244 premiere=250000 derniere=499999
part-r-00002
lignes=250443 premiere=500000 derniere=749998
part-r-00003
lignes=250195 premiere=750000 derniere=999999
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 25 Déséquilibre des plages fixes sur le million de nombres biaisés.



TP 3 MapReduce • 13 octobre 2026

18_tri_biaise

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar ma.bigdata.tp3.tri.TriSimple -D
tri.reducers=4 tp3/tri/biaise_1M.txt tp3/out/captures_1791905161/18_tri_biaise
```

Horodatage UTC et statut

```
2026-10-13 15:32:26 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:32:45 INFO  Job:1747 - Job job_1791904987268_0013 running in uber mode : false
2026-10-13 15:33:24 INFO  Job:1765 - Job job_1791904987268_0013 completed successfully
               Map input records=1000000
               Map output records=1000000
               Combine input records=0
               Combine output records=0
               Reduce input groups=420656
               Reduce output records=1000000
```

Extrait de la sortie HDFS

```
Premières valeurs : 0 0 0 0 0
1000000 lignes au total
Dernières valeurs : 999968 999971 999974 999981 999988
```

Effectifs et bornes par reducer

```
part-r-00000
lignes=706980 premiere=0 derniere=249998
part-r-00001
lignes=134006 premiere=250000 derniere=499999
part-r-00002
lignes=89755 premiere=500000 derniere=749996
part-r-00003
lignes=69259 premiere=750002 derniere=999988
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

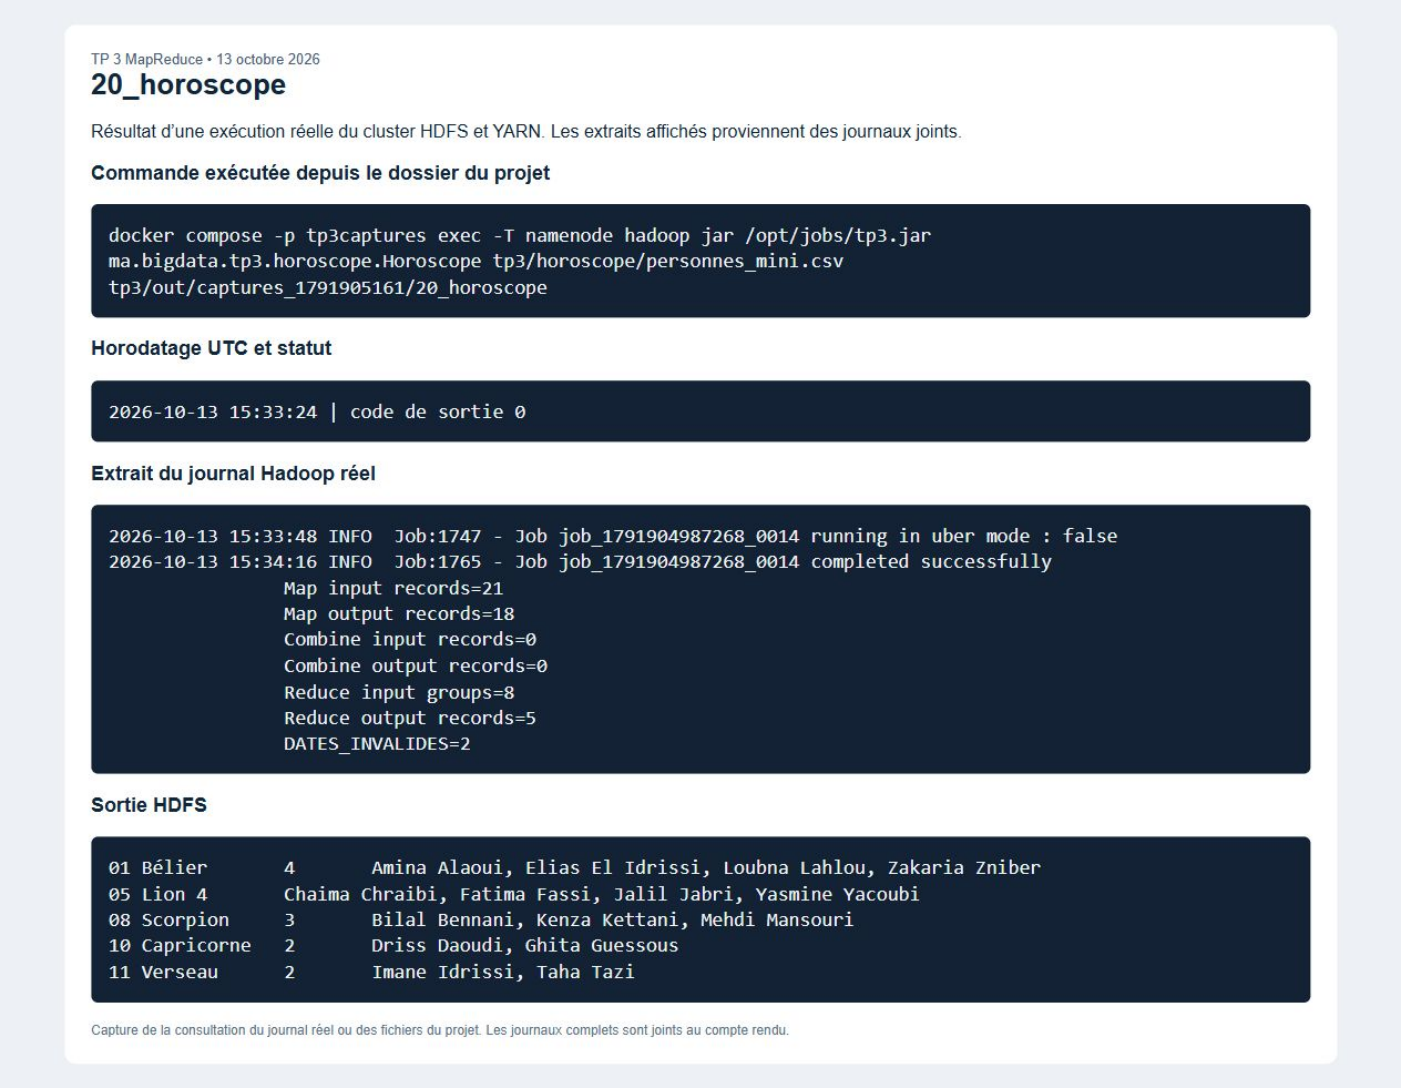
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 26 Tri global par échantillonnage et bornes TotalOrderPartitioner.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 27 Groupes zodiacaux avec au moins deux personnes et dates invalides.



TP 3 MapReduce • 13 octobre 2026

20_horoscope

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar
ma.bigdata.tp3.horoscope.Horoscope tp3/horoscope/personnes_mini.csv
tp3/out/captures_1791905161/20_horoscope
```

Horodatage UTC et statut

```
2026-10-13 15:33:24 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:33:48 INFO  Job:1747 - Job job_1791904987268_0014 running in uber mode : false
2026-10-13 15:34:16 INFO  Job:1765 - Job job_1791904987268_0014 completed successfully
               Map input records=21
               Map output records=18
               Combine input records=0
               Combine output records=0
               Reduce input groups=8
               Reduce output records=5
               DATES_INVALIDES=2
```

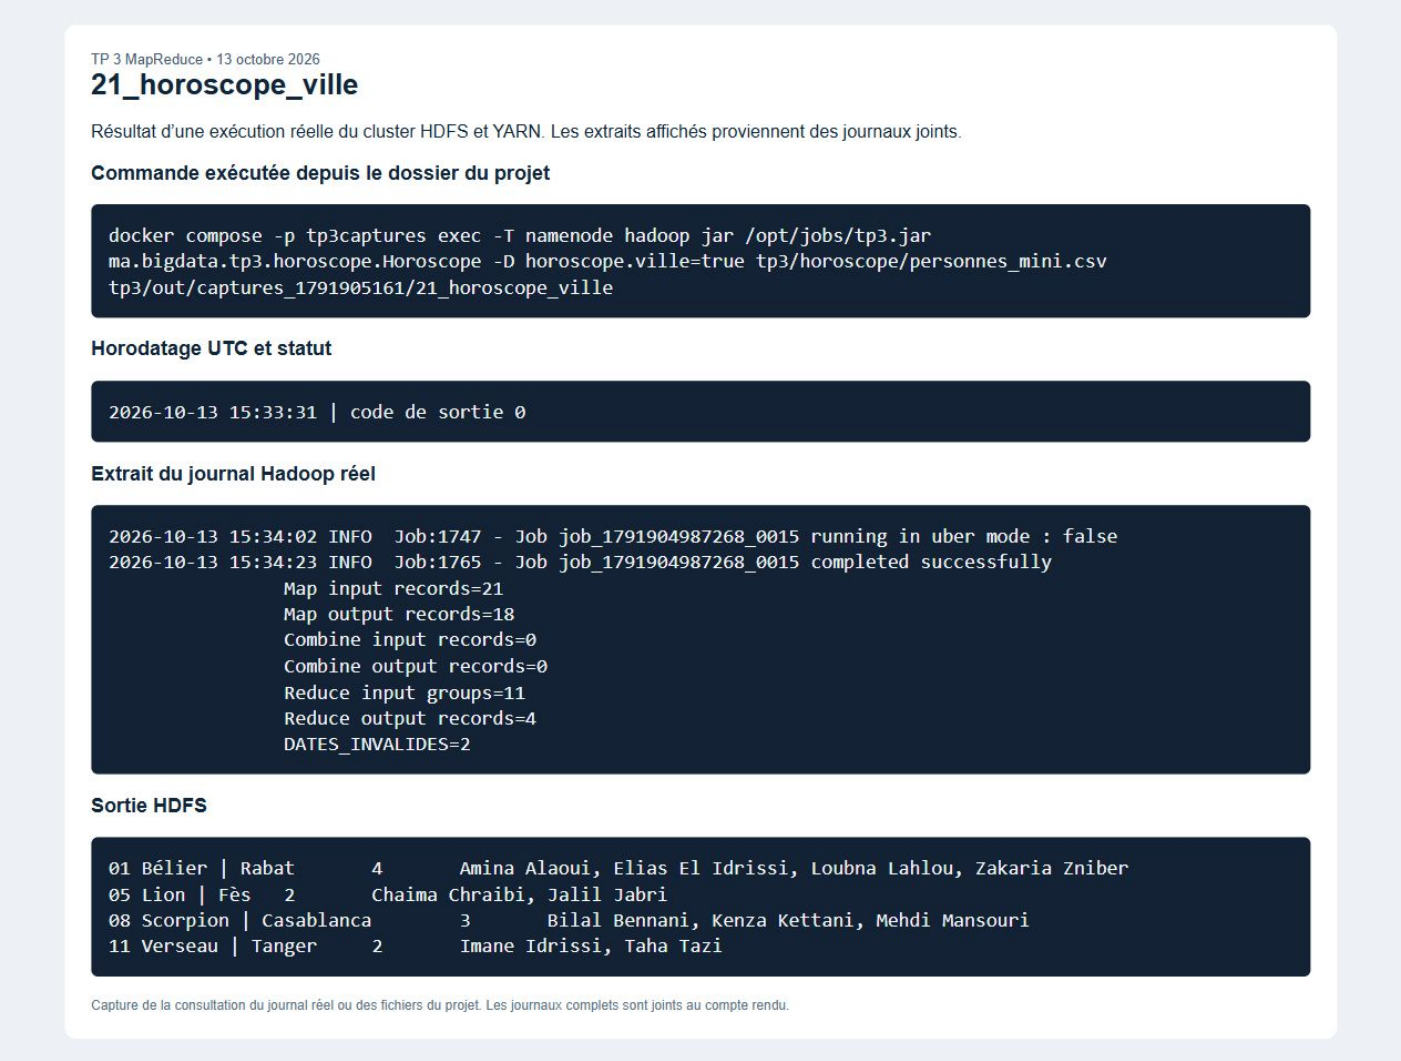
Sortie HDFS

```
01 Bélier       4       Amina Alaoui, Elias El Idrissi, Loubna Lahlou, Zakaria Zniber
05 Lion 4       Chaima Chraibi, Fatima Fassi, Jalil Jabri, Yasmine Yacoubi
08 Scorpion     3       Bilal Bennani, Kenza Kettani, Mehdi Mansouri
10 Capricorne   2       Driss Daoudi, Ghita Guessous
11 Verseau      2       Imane Idrissi, Taha Tazi
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

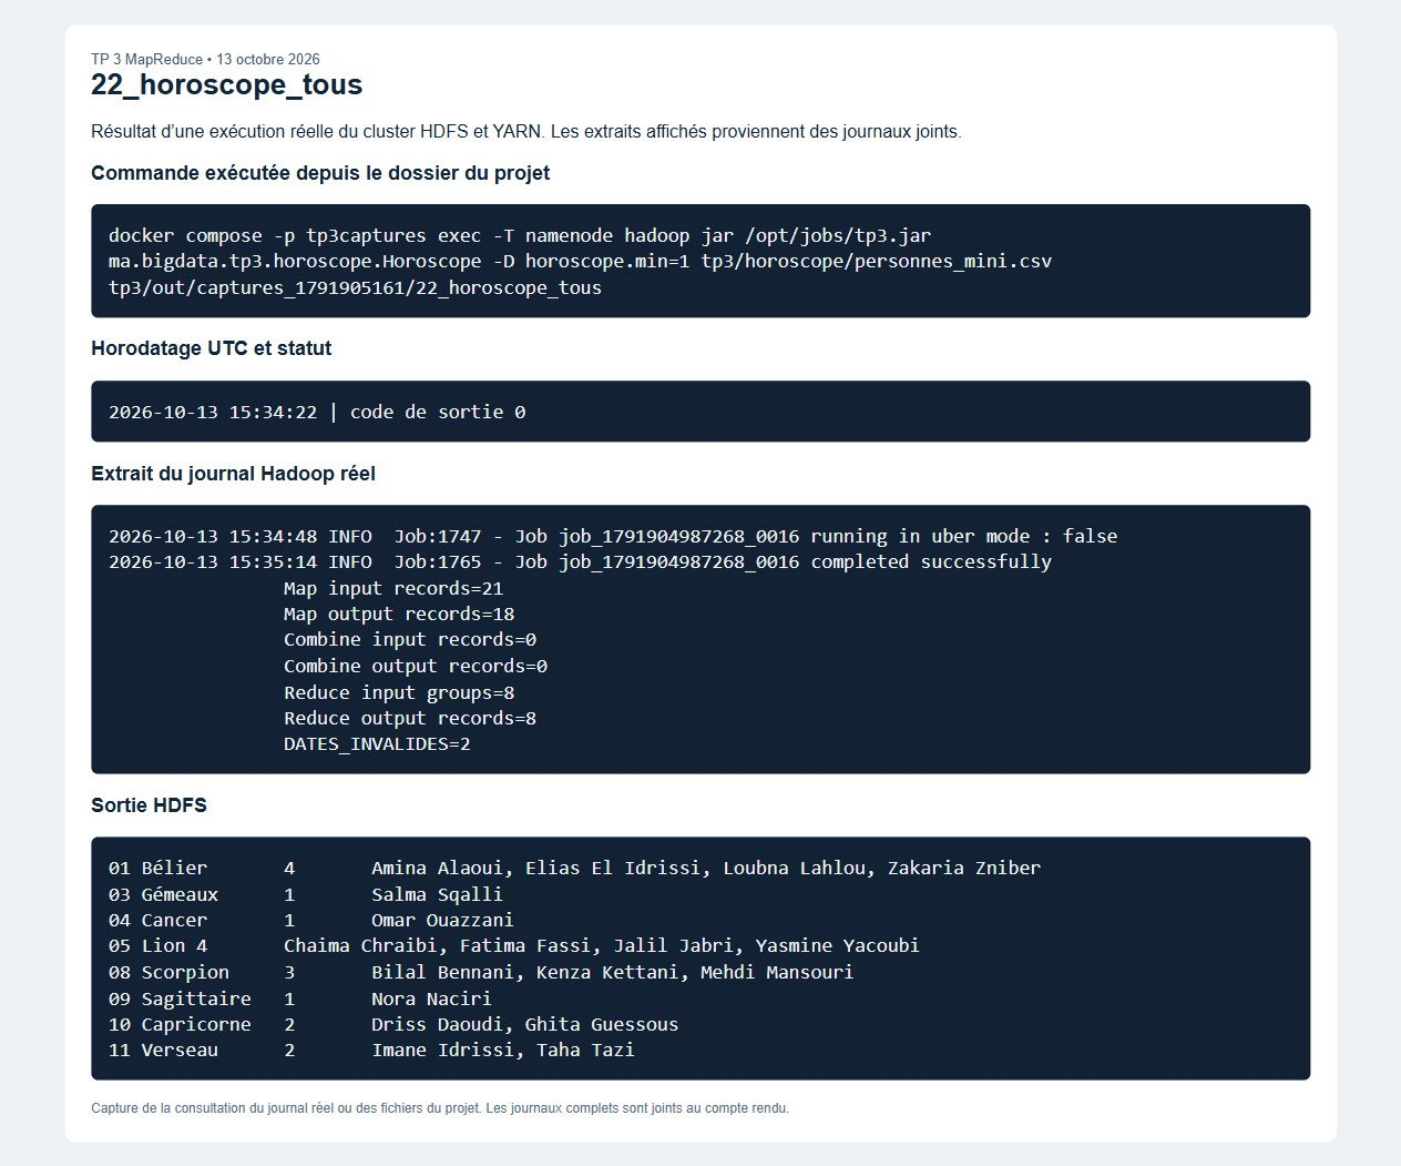
Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 28 Regroupement par signe et ville.



Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 29 Tous les groupes valides avec le seuil à une personne.



TP 3 MapReduce • 13 octobre 2026

22_horoscope_tous

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar
ma.bigdata.tp3.horoscope.Horoscope -D horoscope.min=1 tp3/horoscope/personnes_mini.csv
tp3/out/captures_1791905161/22_horoscope_tous
```

Horodatage UTC et statut

```
2026-10-13 15:34:22 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:34:48 INFO  Job:1747 - Job job_1791904987268_0016 running in uber mode : false
2026-10-13 15:35:14 INFO  Job:1765 - Job job_1791904987268_0016 completed successfully
               Map input records=21
               Map output records=18
               Combine input records=0
               Combine output records=0
               Reduce input groups=8
               Reduce output records=8
               DATES_INVALIDES=2
```

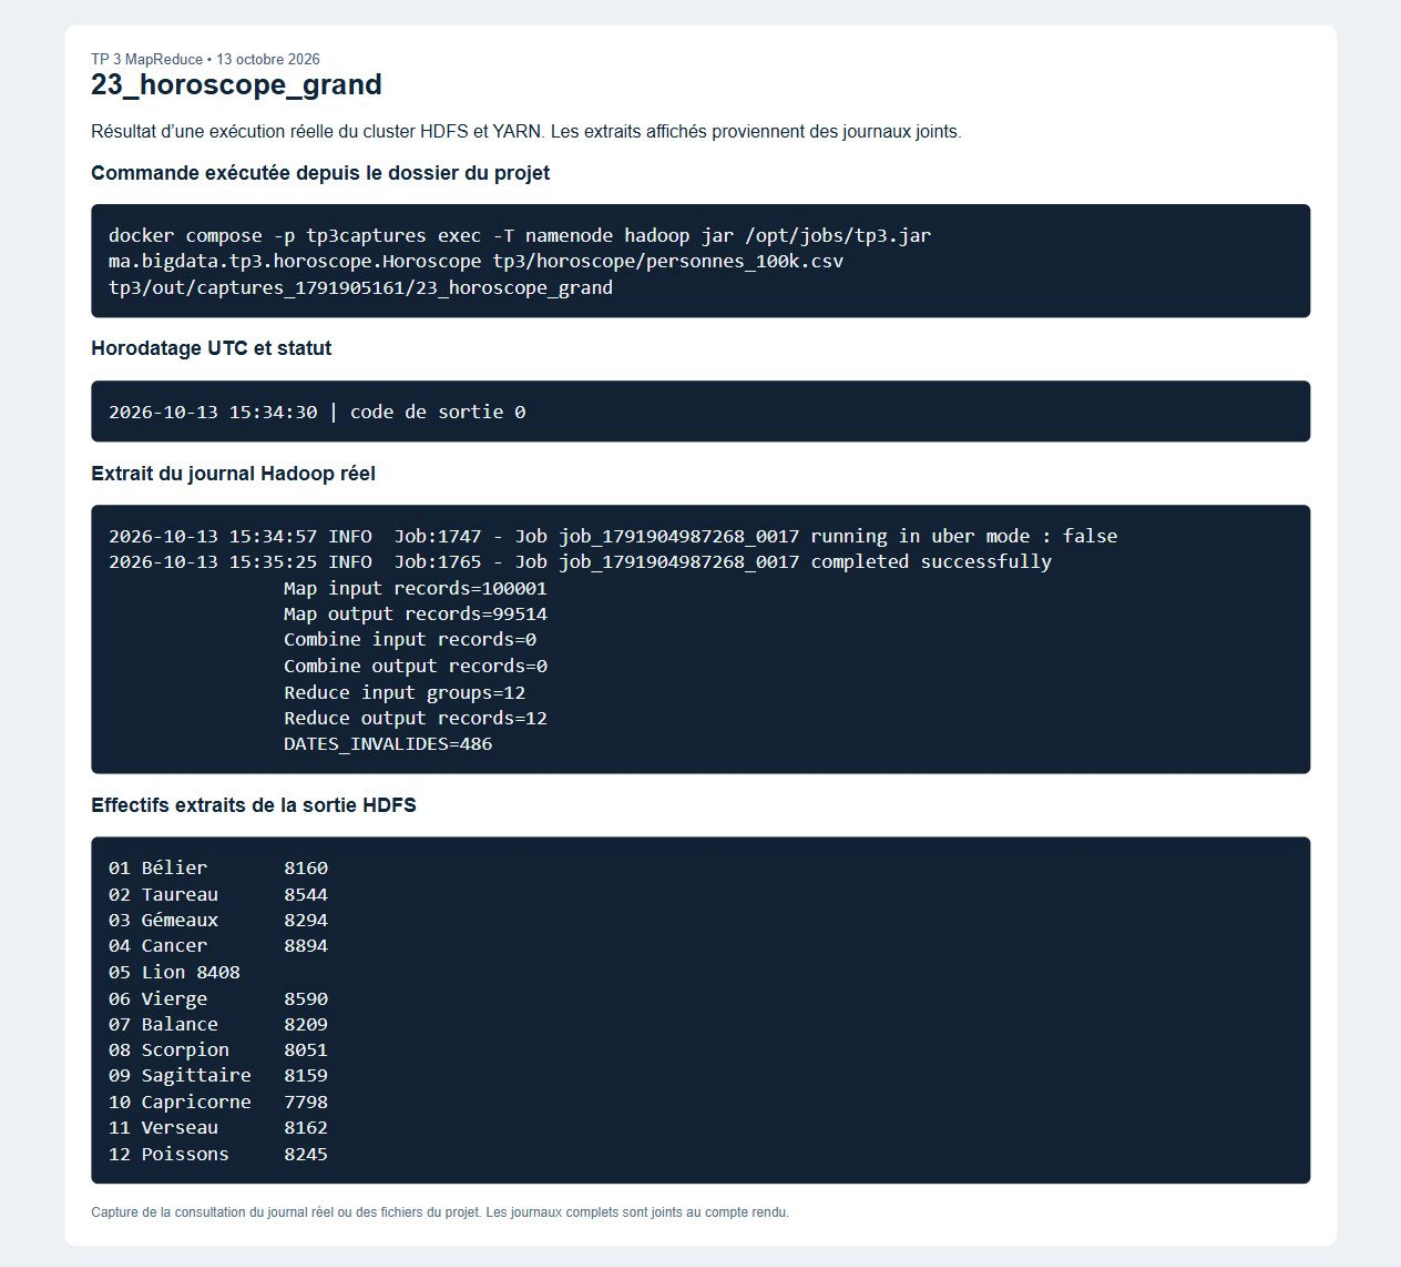
Sortie HDFS

```
01 Bélier       4       Amina Alaoui, Elias El Idrissi, Loubna Lahlou, Zakaria Zniber
03 Gémeaux      1       Salma Sqalli
04 Cancer       1       Omar Ouazzani
05 Lion 4       Chaima Chraibi, Fatima Fassi, Jalil Jabri, Yasmine Yacoubi
08 Scorpion     3       Bilal Bennani, Kenza Kettani, Mehdi Mansouri
09 Sagittaire   1       Nora Naciri
10 Capricorne   2       Driss Daoudi, Ghita Guessous
11 Verseau      2       Imane Idrissi, Taha Tazi
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 30 Application sur cent mille personnes.



TP 3 MapReduce • 13 octobre 2026

23_horoscope_grand

Résultat d'une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar
ma.bigdata.tp3.horoscope.Horoscope tp3/horoscope/personnes_100k.csv
tp3/out/captures_1791905161/23_horoscope_grand
```

Horodatage UTC et statut

```
2026-10-13 15:34:30 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:34:57 INFO  Job:1747 - Job job_1791904987268_0017 running in uber mode : false
2026-10-13 15:35:25 INFO  Job:1765 - Job job_1791904987268_0017 completed successfully
               Map input records=100001
               Map output records=99514
               Combine input records=0
               Combine output records=0
               Reduce input groups=12
               Reduce output records=12
               DATES_INVALIDES=486
```

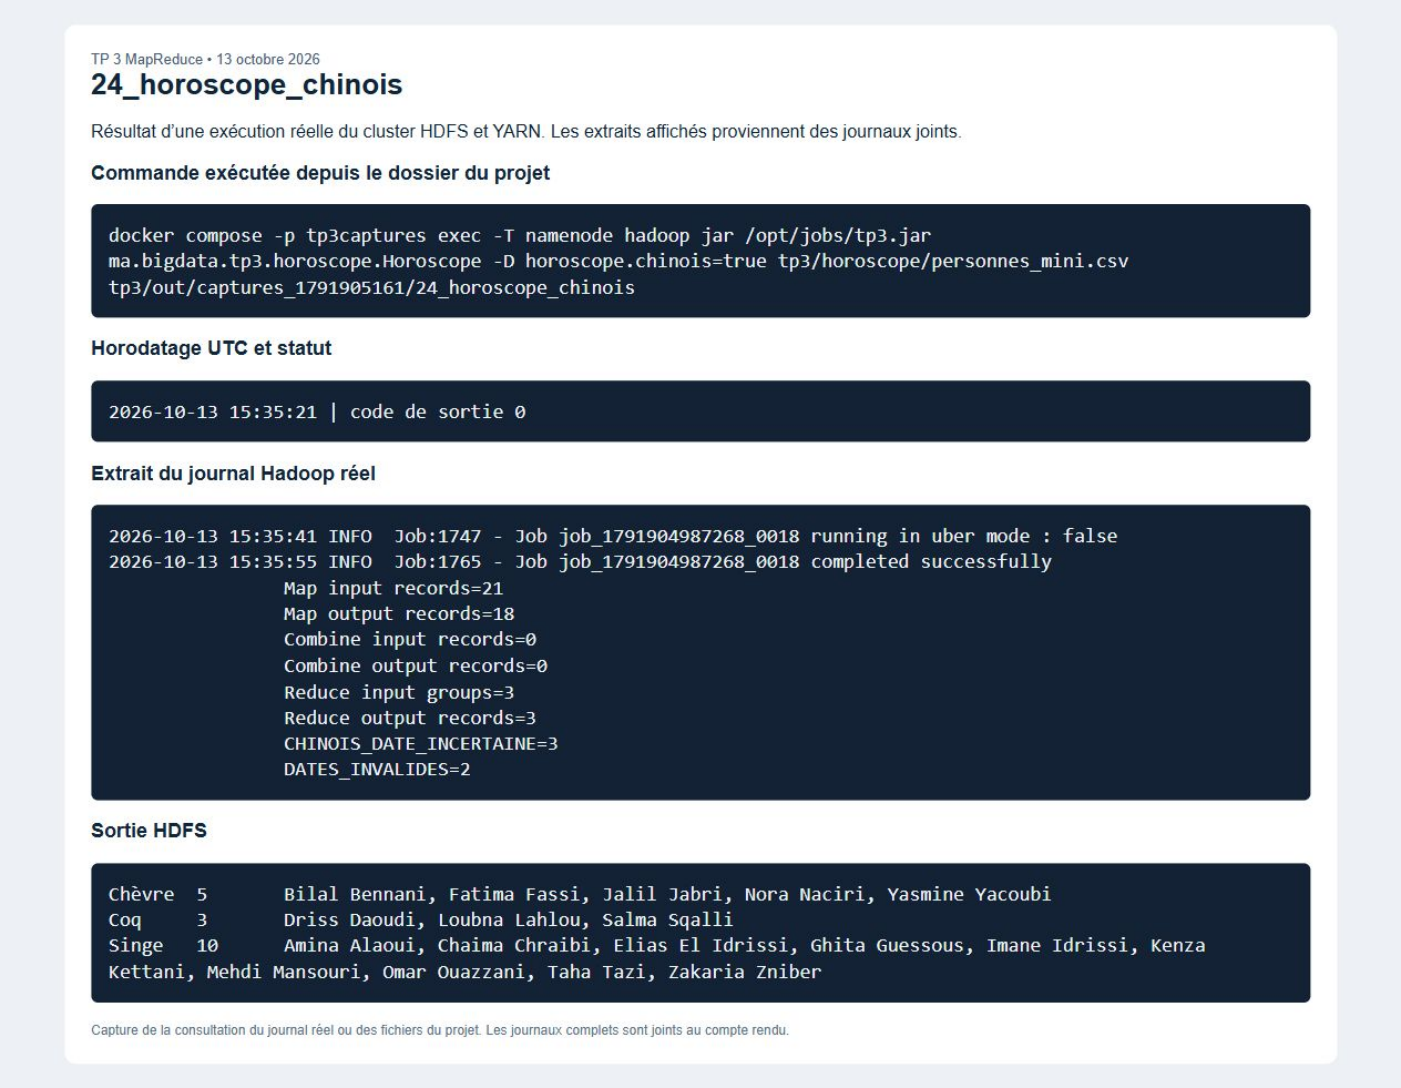
Effectifs extraits de la sortie HDFS

```
01 Bélier       8160
02 Taureau      8544
03 Gémeaux      8294
04 Cancer       8894
05 Lion 8408
06 Vierge       8590
07 Balance      8209
08 Scorpion     8051
09 Sagittaire   8159
10 Capricorne   7798
11 Verseau      8162
12 Poissons     8245
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 31 Bonus chinois et compteur des dates d’interprétation incertaine.



TP 3 MapReduce • 13 octobre 2026

24_horoscope_chinois

Résultat d’une exécution réelle du cluster HDFS et YARN. Les extraits affichés proviennent des journaux joints.

Commande exécutée depuis le dossier du projet

```
docker compose -p tp3captures exec -T namenode hadoop jar /opt/jobs/tp3.jar
ma.bigdata.tp3.horoscope.Horoscope -D horoscope.chinois=true tp3/horoscope/personnes_mini.csv
tp3/out/captures_1791905161/24_horoscope_chinois
```

Horodatage UTC et statut

```
2026-10-13 15:35:21 | code de sortie 0
```

Extrait du journal Hadoop réel

```
2026-10-13 15:35:41 INFO  Job:1747 - Job job_1791904987268_0018 running in uber mode : false
2026-10-13 15:35:55 INFO  Job:1765 - Job job_1791904987268_0018 completed successfully
               Map input records=21
               Map output records=18
               Combine input records=0
               Combine output records=0
               Reduce input groups=3
               Reduce output records=3
               CHINOIS_DATE_INCERTAINE=3
               DATES_INVALIDES=2
```

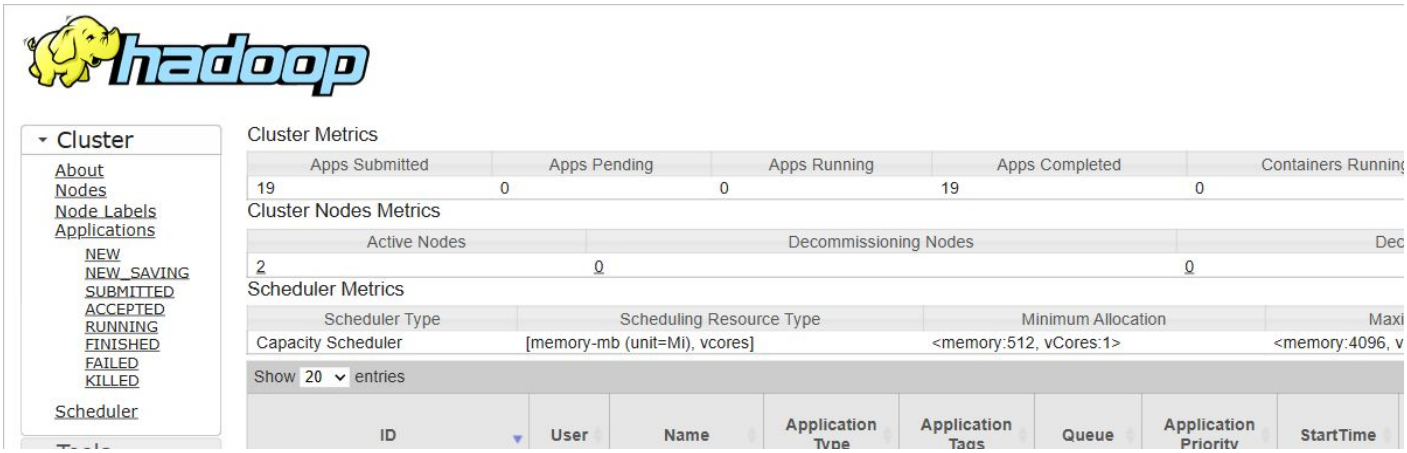
Sortie HDFS

```
Chèvre  5       Bilal Bennani, Fatima Fassi, Jalil Jabri, Nora Naciri, Yasmine Yacoubi
Coq     3       Driss Daoudi, Loubna Lahlou, Salma Sqalli
Singe   10      Amina Alaoui, Chaima Chraibi, Elias El Idrissi, Ghita Guessous, Imane Idrissi, Kenza
Kettani, Mehdi Mansouri, Omar Ouazzani, Taha Tazi, Zakaria Zniber
```

Capture de la consultation du journal réel ou des fichiers du projet. Les journaux complets sont joints au compte rendu.

Source : capture de la consultation du journal réel ou des fichiers du projet. Le journal complet est conservé dans le dossier traces.

Figure 32 Applications du TP terminées dans l’interface YARN.



Source : capture de l’interface web du cluster.